

ANEXO D

Desarrollo experimental del módulo visual-temporal sobre FIgLib/HPWREN

Sistema multimodal para la detección temprana de incendios forestales
mediante inteligencia artificial

Antón Soto

Máster en Big Data, Data Science e Inteligencia Artificial

Universidad Complutense de Madrid

Índice

1	Objetivo y alcance del anexo	1
2	Conjunto de datos FIgLib/HPWREN	1
2.1	Estructura del conjunto	1
2.2	Referencia temporal y etiquetado débil	2
2.3	Separación por evento	2
3	Problema visual y metodología experimental	3
3.1	Clasificador visual	3
3.2	Preprocesado y entrenamiento	3
3.3	Métricas y comparaciones	4
4	Evolución experimental hasta el baseline final	4
5	Efecto de la resolución espacial	5
5.1	Diseño de la comparación	5
5.2	Resultados	5
6	Información local y modelo multiescala	6
7	Análisis de casos difíciles	6
8	De la clasificación visual a la detección temporal	7
9	Modelo temporal aprendido mediante GRU	7
9.1	Características y arquitectura	7
9.2	Resultados temporales	8
10	Interpretación conjunta del módulo	8
11	Limitaciones	9
12	Reproducibilidad y trazabilidad	9
13	Decisiones metodológicas que condicionan la lectura de los resultados	10
13.1	Por qué el evento es la unidad experimental	10
13.2	Uso de validación y test	10
13.3	Sobreajuste y selección del checkpoint	10
14	Resumen de la evolución experimental	11
15	Bootstrap pareado: procedimiento e interpretación	12
16	Detalle del bloque temporal	12
16.1	Por qué una media móvil es un baseline razonable	12
16.2	Qué aprende la GRU	13
17	Coste computacional y condicionantes del desarrollo	13
18	Líneas de continuación específicas del módulo	13
19	Conclusiones del anexo	14
	Referencias	14

1. Objetivo y alcance del anexo

Este anexo desarrolla con más detalle el módulo visual-temporal presentado de forma resumida en la memoria principal. El objetivo de esta parte del trabajo fue estudiar si una secuencia de imágenes procedente de cámaras forestales permite obtener una señal útil de humo y, a partir de su evolución, generar una alerta temprana con un comportamiento razonable frente a falsas activaciones.

El desarrollo se dividió en dos problemas relacionados pero distintos. El primero fue la clasificación visual de imágenes individuales. Para cada frame I_t se estimó una probabilidad $p_t = P(\text{smoke} | I_t)$. El segundo fue la detección temporal: dada la sucesión de probabilidades producidas por el clasificador, se estudió cuándo la evidencia acumulada era suficiente para considerar que existía una alerta.

El trabajo se realizó sobre FgLib/HPWREN, un conjunto formado por secuencias de cámaras fijas asociadas a incendios forestales. La estructura temporal del dataset permitió pasar de una evaluación puramente frame a frame a una evaluación a nivel de evento, que es la que resulta más próxima al objetivo de detección temprana.

No se pretende reproducir aquí toda la evolución exploratoria del desarrollo original. Se recogen las decisiones metodológicas, los experimentos que determinaron el modelo final y las limitaciones que resultan relevantes para interpretar los resultados incluidos en la memoria.




Figura 1: Esquema general del módulo visual-temporal. El clasificador visual genera una probabilidad de humo para cada imagen y la etapa temporal utiliza su evolución reciente para producir una señal de alerta.

2. Conjunto de datos FgLib/HPWREN

2.1. Estructura del conjunto

FgLib está construido a partir de imágenes capturadas por la infraestructura HPWREN mediante cámaras fijas situadas en emplazamientos elevados. Cada secuencia agrupa imágenes tomadas alrededor de un evento de incendio y conserva una referencia temporal relativa. Esta organización es especialmente útil porque permite trabajar con la imagen aislada y, al mismo tiempo, estudiar cómo cambia la señal visual a lo largo del tiempo.

La preparación completa utilizada en este trabajo localizó 519 secuencias y aproximadamente 41 187 imágenes físicas. Tras aplicar las reglas de etiquetado empleadas en el entrenamiento visual quedaron 23 480 imágenes entrenables, correspondientes a 333 eventos diferentes. Durante la preparación también se

eliminaron ficheros corruptos o no decodificables.



Figura 2: Ejemplo de una escena capturada por la infraestructura HPWREN. Las cámaras cubren grandes extensiones de terreno y, en muchos casos, el humo ocupa una fracción reducida de la imagen.

2.2. Referencia temporal y etiquetado débil

Los nombres de los frames incluyen el desplazamiento temporal respecto a una referencia de la secuencia. Por ejemplo, valores como -01800 , -00600 , $+00000$ o $+00600$ permiten situar cada imagen antes o después de dicha referencia. El instante $t = 0$ es útil para ordenar la secuencia, pero no debe interpretarse como una anotación exacta del primer píxel de humo visible.

Esta incertidumbre obligó a utilizar un etiquetado conservador durante el entrenamiento visual. Se consideraron negativos los frames con $t \leq -1200$ s y positivos los frames con $t \geq +900$ s. La región intermedia $-1200 < t < +900$ s se excluyó del entrenamiento supervisado. La decisión reduce el ruido de etiqueta, aunque implica renunciar a parte de los frames más cercanos al inicio del evento, precisamente donde el humo puede ser más débil.




Figura 3: Evolución de una secuencia de FigLib. La referencia temporal organiza el evento, pero no constituye una frontera exacta entre ausencia y presencia visible de humo.

2.3. Separación por evento

Las imágenes consecutivas de una misma secuencia son muy parecidas. Por este motivo, una partición aleatoria por imagen produciría fuga de información entre entrenamiento y evaluación. La unidad de partición empleada fue el evento completo: todos los frames pertenecientes a un mismo incendio se asignan al mismo subconjunto.

La partición final utilizada en los experimentos principales se muestra en la Tabla 1.

Tabla 1: Partición principal de FIgLib utilizada en los experimentos finales.

Conjunto	Imágenes	Eventos
Entrenamiento	15 907	233
Validación	3 812	50
Test	3 761	50

La validación se utilizó para seleccionar checkpoints, umbrales y reglas temporales. El conjunto de test permaneció separado hasta la evaluación final. Esta separación se mantuvo también en las comparaciones estadísticas entre modelos.

3. Problema visual y metodología experimental

3.1. Clasificador visual

El problema visual se formuló como una clasificación binaria entre *no_smoke* y *smoke*. La arquitectura de referencia fue ResNet18 preentrenada y posteriormente ajustada sobre FIgLib. La última capa se adaptó a dos clases y la salida se transformó en una probabilidad mediante Softmax. La señal utilizada por el módulo temporal es la probabilidad de la clase humo, p_t .

La elección de ResNet18 respondió a un criterio práctico. El objetivo del trabajo no era realizar una competición exhaustiva entre arquitecturas, sino disponer de un backbone suficientemente estable para estudiar decisiones de diseño relacionadas con resolución, información local y temporalidad. Se realizó una prueba con EfficientNet-B0, pero no mostró una mejora clara respecto a las mejores configuraciones basadas en ResNet18.

3.2. Preprocesado y entrenamiento

En el modelo Full384, la configuración finalmente utilizada, la evaluación aplica **Resize(440)** seguido de **CenterCrop(384)** y normalización. Durante el entrenamiento se añadió *RandomResizedCrop*, volteo horizontal y cambios moderados de color. Las transformaciones aleatorias se limitaron al conjunto de entrenamiento.

El entrenamiento se realizó con AdamW, un learning rate inicial de 3×10^{-4} y *weight decay* de 10^{-4} . El batch físico fue 16 y se utilizó acumulación de gradiente durante cuatro pasos, de forma que el batch efectivo fue 64. Esta decisión estuvo condicionada por la memoria de GPU disponible al trabajar con imágenes de 384×384 .

Tabla 2: Configuración principal del clasificador visual Full384.

Parámetro	Valor
Arquitectura	ResNet18 preentrenada
Resolución de entrada	384×384
Optimizador	AdamW
Learning rate inicial	3×10^{-4}
Weight decay	10^{-4}
Batch físico / efectivo	16 / 64
Scheduler	Cosenoidal
Precisión mixta	AMP
Pérdida	Cross Entropy ponderada

3.3. Métricas y comparaciones

El rendimiento no se evaluó únicamente mediante accuracy. En un sistema de vigilancia, una sensibilidad elevada puede ser poco útil si produce demasiadas falsas alarmas. Por ello se analizaron conjuntamente Balanced Accuracy, precision, recall, F1, AUC y tasa de falsos positivos (FPR). La FPR, definida como $FP/(FP + TN)$, tuvo un peso especial durante la interpretación de los modelos.

Cuando dos configuraciones se compararon sobre los mismos eventos se utilizó bootstrap pareado a nivel de evento. En cada una de 10 000 réplicas se remuestrearon eventos completos con reemplazo y ambos modelos fueron evaluados sobre exactamente la misma réplica. De esta forma se evitó tratar los frames temporalmente correlacionados como observaciones independientes y se pudo estimar la incertidumbre de la diferencia entre modelos.

4. Evolución experimental hasta el baseline final

El desarrollo inicial se realizó de forma incremental. Los primeros prototipos sirvieron para comprobar el pipeline y entender qué tipos de errores dominaban el problema. Un primer modelo alcanzó un AUC razonable, pero su recall a umbral 0.5 era muy bajo. Reducir el umbral aumentaba la sensibilidad, aunque también mostraba que el comportamiento operativo dependía fuertemente de la regla de decisión.

Las siguientes iteraciones ampliaron el número de secuencias, introdujeron ResNet18, mayor resolución y ejemplos negativos difíciles. También se probaron recortes locales y EfficientNet-B0. Estas pruebas fueron útiles para identificar dos problemas que después guiaron los experimentos controlados: la presencia de falsos positivos ante patrones atmosféricos ambiguos y la dificultad para detectar columnas de humo pequeñas o lejanas.

A medida que avanzó el trabajo se redujo el peso de las comparaciones entre prototipos entrenados con particiones diferentes y se priorizaron benchmarks comunes. El baseline Full30c, basado en ResNet18 y entrada 224×224 , se convirtió en la referencia estable para el estudio posterior de resolución.

A umbral 0.5, Full30c obtuvo Balanced Accuracy 0.7450, precision 0.8220, recall 0.6689, F1 0.7376, AUC 0.7988 y FPR 0.1788. Estos valores no eran el resultado final del trabajo, pero proporcionaban una base reproducible sobre la que modificar una variable cada vez.




Figura 4: Evolución de las pérdidas de entrenamiento y validación en Full30c. La divergencia entre ambas curvas motivó la selección de checkpoints mediante validación en lugar de conservar simplemente la última época.

5. Efecto de la resolución espacial

5.1. Diseño de la comparación

La comparación entre Full224 y Full384 fue uno de los experimentos centrales. Ambos modelos utilizaron ResNet18, la misma partición por evento y una metodología de entrenamiento equivalente. La principal variable modificada fue la resolución de entrada.

El motivo era directo: en varias escenas de FigLib, el humo ocupa una región muy pequeña. Una imagen de 384×384 contiene aproximadamente 2.94 veces más posiciones espaciales que una de 224×224 . Esto no implica que toda esa información adicional sea útil, pero sí reduce la pérdida de detalle provocada por el redimensionado.




Figura 5: Comparación del preprocesado de una misma escena con las configuraciones Full224 y Full384.

5.2. Resultados

La Tabla 3 recoge los resultados sobre el mismo test y a umbral 0.5.

Tabla 3: Comparación entre Full224 y Full384.

Métrica	Full224	Full384	Diferencia
Balanced Accuracy	0.7450	0.7989	+0.0539
Precision	0.8220	0.9019	+0.0799
Recall	0.6689	0.6906	+0.0217
F1	0.7376	0.7822	+0.0446
AUC	0.7988	0.8386	+0.0398
FPR	0.1788	0.0927	-0.0862

La mejora más clara apareció en los falsos positivos. Full224 produjo 301 falsos positivos y Full384 156, una reducción aproximada del 48 % sobre exactamente el mismo conjunto. El recall también aumentó ligeramente, por lo que la mejora de especificidad no se obtuvo sacrificando sensibilidad.

El bootstrap por evento confirmó que las diferencias en Balanced Accuracy, precision y FPR eran consistentes dentro del benchmark. Para Balanced Accuracy, la diferencia fue +0,0539 con un intervalo aproximado $[+0,0118, +0,0944]$. Para FPR, la diferencia fue $-0,0862$ con un intervalo $[-0,1491, -0,0299]$. En cambio, los intervalos de recall, F1 y AUC incluyeron el cero, por lo que esas mejoras puntuales deben interpretarse con más cautela.

Estos resultados llevaron a adoptar Full384 como modelo visual de referencia. La conclusión no es que aumentar indefinidamente la resolución sea siempre mejor, sino que en esta comparación concreta la representación de 384×384 ofreció un equilibrio claramente más favorable.

6. Información local y modelo multiescala

Tras mejorar la resolución se estudió si el modelo podía beneficiarse de una representación explícita de regiones locales. La hipótesis era que una columna de humo pequeña podía quedar diluida dentro de una escena panorámica, mientras que dentro de un recorte ocuparía una proporción mayor.

La arquitectura multiescala combinó una vista global con cuatro tiles locales de 384×384 . Full384 se utilizó como extractor visual y las representaciones locales se agregaron mediante un mecanismo aprendido antes de combinarse con la representación global.

El resultado fue un cambio claro de perfil. El recall aumentó de 0.6906 a 0.7594, pero la FPR pasó de 0.0927 a 0.1771. La precision también disminuyó de 0.9019 a 0.8412. El modelo detectaba más positivos, pero activaba con mayor frecuencia sobre estructuras ambiguas.

Tabla 4: Full384 frente al modelo multiescala.

Métrica	Full384	Multiescala	Diferencia
Balanced Accuracy	0.7989	0.7912	-0.0077
Precision	0.9019	0.8412	-0.0608
Recall	0.6906	0.7594	+0.0688
F1	0.7822	0.7982	+0.0160
AUC	0.8386	0.8493	+0.0107
FPR	0.0927	0.1771	+0.0844

El experimento muestra que la información local contiene señal útil, pero también magnifica patrones que visualmente pueden parecer humo. Nubes, bruma, reflejos y zonas de baja visibilidad se vuelven más dominantes cuando se analizan en un recorte. Se probó además una fusión entre Full384 y el modelo multiescala, pero no apareció una configuración que mejorase simultáneamente sensibilidad y falsas alarmas. Por ese motivo Full384 se mantuvo como referencia para la etapa temporal.

7. Análisis de casos difíciles

El análisis cualitativo de los errores ayudó a interpretar los resultados cuantitativos. Entre los positivos difíciles aparecen humos tenues, lejanos, laterales o con poco contraste. En el extremo contrario, algunos negativos contienen estructuras difusas que se parecen localmente a una columna de humo.




Figura 6: Variabilidad de la clase positiva en FgLib.



Figura 7: Ejemplos de condiciones negativas que pueden generar activaciones incorrectas.

La relación con los experimentos anteriores es clara. La mayor resolución ayuda cuando la señal positiva es pequeña, mientras que el análisis local mejora sensibilidad pero también puede amplificar los confusores. Esto explica por qué una mejora de recall no debe interpretarse de forma aislada y por qué la FPR fue una métrica central durante el desarrollo.

8. De la clasificación visual a la detección temporal

Una cámara no produce una imagen aislada, sino una secuencia. Utilizar directamente la predicción de cada frame puede generar alertas por picos puntuales. Para reducir ese efecto se evaluaron reglas causales de persistencia sobre las probabilidades de Full384.

La regla seleccionada en validación fue una media móvil de cinco observaciones. En cada instante se calcula $\bar{p}_t = (1/5) \sum_{j=0}^4 p_{t-j}$ y se compara con el umbral fijado en validación. La regla no usa frames futuros, por lo que puede ejecutarse de forma causal.

Sobre los 50 eventos de test, la media móvil detectó el 88 % de los eventos en algún momento posterior a $t = 0$. El 36 % fue detectado antes de 300 s, el 58 % antes de 600 s y el 72 % antes de 900 s. La mediana del retraso fue 361 s. El 18 % de los eventos presentó alguna activación en la región claramente pre-evento y seis eventos no llegaron a ser detectados después de la referencia.

Estos resultados mostraron que la persistencia temporal ayuda a convertir las probabilidades del clasificador en una señal más estable, pero la regla sigue siendo manual: todas las observaciones de la ventana reciben el mismo tratamiento y no se aprende la forma concreta que debe tener una evolución temporal de interés.

9. Modelo temporal aprendido mediante GRU

9.1. Características y arquitectura

Para sustituir las reglas manuales por un mecanismo aprendido se entrenó una GRU. El clasificador Full384 permaneció congelado y produjo la señal visual. Para cada instante se construyó el vector $x_t = (p_t, \Delta p_t, \Delta t_t)$, donde $\Delta p_t = p_t - p_{t-1}$ y Δt_t representa el intervalo temporal entre observaciones.

La GRU recibe ventanas causales de ocho observaciones, $x_{t-7}, \dots, x_t$. La dimensión de entrada es 3, el estado oculto tiene dimensión 32 y se utiliza una única capa recurrente. La cabeza final transforma 32 características en 16 y después en un logit de alerta. Se empleó ReLU, dropout 0.2, AdamW con learning rate 10^{-3} y weight decay 10^{-4} .

El etiquetado temporal difiere del utilizado para entrenar el clasificador visual. En el modelo visual se exigía $t \geq +900$ s para considerar un positivo de alta confianza; la GRU, en cambio, pretende aprender cuándo debe empezar a emitirse la alerta y utiliza $t \geq 0$ como región positiva temporal. Esta diferencia responde a objetivos distintos, no a una contradicción entre etiquetas.

Tabla 5: Configuración principal del modelo GRU.

Parámetro	Valor
Dimensión de entrada	3
Longitud de secuencia	8
Hidden size	32
Capas GRU	1
Capa intermedia	16
Dropout	0.2
Optimizador	AdamW
Learning rate	10^{-3}
Weight decay	10^{-4}
Máximo de épocas	50
Paciencia	8

El mejor checkpoint se seleccionó en validación y correspondió a la época 49, con AUC de validación aproximadamente 0.8628. El umbral de alerta se fijó en 0.85 antes de evaluar el conjunto de test.

9.2. Resultados temporales

La comparación final se realizó sobre los mismos 50 eventos. La Tabla 6 resume los resultados.

Tabla 6: Comparación entre la media móvil de cinco observaciones y la GRU.

Métrica	Rolling mean 5	GRU
Cobertura post- $t = 0$	0.88	0.96
Antes de 300 s	0.36	0.56
Antes de 600 s	0.58	0.72
Antes de 900 s	0.72	0.90
Antes de 1800 s	0.88	0.94
Alertas en región clear-pre	0.18	0.28
Mediana del retraso	361 s	210.5 s
Eventos no detectados	6	2

La GRU mejora de forma especialmente clara la detección durante los primeros minutos. Antes de 900 s la cobertura aumenta del 72 % al 90 %, y la mediana del retraso disminuye de 361 a 210.5 s, una reducción cercana al 42 %. También disminuye el número de eventos completamente no detectados, de seis a dos.

El coste de esta mejora es una mayor sensibilidad antes de la referencia: la proporción de eventos con una activación en la región claramente pre-evento aumenta del 18 % al 28 %. Por tanto, la GRU no domina a la regla heurística en todos los aspectos. Su perfil prioriza rapidez y cobertura, mientras que la media móvil es más conservadora frente a activaciones prematuras.

10. Interpretación conjunta del módulo

Los experimentos permiten separar tres efectos. El primero es espacial: preservar más detalle en la imagen ayudó a reducir falsas detecciones y mejorar la discriminación del clasificador. El segundo es local: los recortes contienen información útil para recuperar señales pequeñas, aunque esa mayor sensibilidad también afecta a patrones ambiguos. El tercero es temporal: utilizar la evolución de las probabilidades permite decidir una alerta con más información que la disponible en un único frame.

La configuración finalmente retenida para la memoria principal utiliza Full384 como clasificador visual y la GRU como modelo temporal aprendido. Full384 no es el modelo con mayor recall de todos los experimentos, pero sí el que ofreció el equilibrio más sólido entre sensibilidad y falsas alarmas. La GRU se

incorporó porque mejoró la cobertura y redujo el retraso respecto a la regla temporal manual, asumiendo explícitamente el aumento de activaciones tempranas.

Este resultado también explica por qué no se buscó una única métrica que resumiese todo el bloque. Una configuración puede mejorar recall y empeorar FPR; otra puede reducir el retraso y aumentar alertas prematuras. En detección temprana, estos compromisos tienen significado operativo y deben mantenerse visibles en la evaluación.

11. Limitaciones

La principal limitación del conjunto es que FIgLib está organizado alrededor de incendios conocidos. No representa una cámara funcionando durante semanas o meses sin ningún evento. Por ello, la FPR a nivel de frame no puede interpretarse directamente como número de falsas alarmas por hora o por día. Una validación operativa necesitaría largos periodos completamente negativos.

También existe una dependencia del dominio visual. Las cámaras pertenecen a una infraestructura y a una región geográfica concretas. Aunque la separación por evento evita que el mismo incendio aparezca en train y test, no garantiza generalización a nuevas ópticas, paisajes, vegetación o condiciones climáticas. Un despliegue en España requeriría una validación específica y, preferiblemente, un conjunto de imágenes geolocalizadas de incendios reales en el territorio objetivo.

El etiquetado temporal es otra fuente de incertidumbre. El instante $t = 0$ es una referencia de la secuencia y no una anotación manual del primer humo visible. El margen usado en el clasificador visual reduce esta ambigüedad, pero hace que parte de la fase incipiente no participe en el entrenamiento de imagen. En el modelo temporal, donde el objetivo es detectar antes, se adoptó una definición distinta de positivo, lo que debe tenerse en cuenta al interpretar las métricas.

Por último, el desarrollo estuvo condicionado por la disponibilidad de cómputo. Gran parte de los experimentos se ejecutó en Google Colab y el salto a 384×384 obligó a reducir el batch físico y utilizar acumulación de gradiente. Esto limitó el número de arquitecturas, resoluciones e hiperparámetros que podían explorarse de manera exhaustiva. Los resultados justifican estudiar resoluciones superiores, pero no permiten asumir que el rendimiento vaya a mejorar de forma monotónica.

12. Reproducibilidad y trazabilidad

Durante el desarrollo se conservaron las particiones por evento, configuraciones de preprocesado, hiperparámetros, checkpoints y predicciones necesarias para reconstruir los experimentos principales. Las decisiones de selección de modelo y umbral se realizaron sobre validación y se congelaron antes de evaluar test.

La comparación Full224–Full384 se realizó sobre el mismo conjunto de eventos y se acompañó de bootstrap pareado a nivel de evento. La comparación temporal entre rolling mean 5 y GRU también se realizó sobre los mismos 50 eventos. Esta trazabilidad es importante porque una parte de los primeros prototipos se desarrolló sobre subconjuntos distintos y sus métricas no deben interpretarse como comparaciones controladas entre sí.

El código y los artefactos utilizados para reproducir el módulo se incluyen en los repositorios indicados en el anexo general de código del TFM. El presente documento se centra en las decisiones experimentales y en los resultados necesarios para interpretar el bloque FIgLib de la memoria principal.

13. Decisiones metodológicas que condicionan la lectura de los resultados

13.1. Por qué el evento es la unidad experimental

FigLib contiene muchos frames por incendio y, dentro de una misma secuencia, imágenes tomadas con pocos segundos de diferencia pueden ser casi idénticas. Esto afecta tanto a la partición de datos como al análisis estadístico. Si se mezclasen frames de un mismo evento entre entrenamiento y test, el modelo podría reconocer el paisaje, la cámara o condiciones visuales muy específicas del incendio sin haber aprendido una representación generalizable del humo.

Por este motivo, el identificador de evento se mantuvo como unidad mínima de separación. En términos prácticos, si un incendio pertenece a entrenamiento, ninguno de sus frames puede aparecer en validación o test. Esta decisión también se mantuvo en el bootstrap: una réplica selecciona incendios completos, no imágenes sueltas. De esta forma la incertidumbre estimada refleja mejor la variabilidad entre eventos, que es la que interesa cuando se pretende generalizar a incendios no observados.

La misma lógica se aplicó al comparar modelos. Siempre que fue posible, dos configuraciones se enfrentaron sobre exactamente los mismos eventos y las mismas imágenes. Esta precaución resultó especialmente importante después de las primeras iteraciones, porque algunos prototipos iniciales se habían entrenado sobre subconjuntos diferentes y sus métricas globales no eran directamente comparables.

13.2. Uso de validación y test

El conjunto de validación se utilizó para tomar decisiones: elegir el checkpoint, seleccionar el umbral de clasificación, comparar configuraciones o fijar una regla temporal. El test se reservó para la evaluación final de la configuración ya seleccionada. Esta separación evita que el propio proceso de prueba termine adaptando indirectamente el sistema al conjunto que se utiliza para reportar resultados.

En el caso de Full384, por ejemplo, se evaluó el umbral estándar 0.5 y también se estudió una selección de umbral sobre validación. El umbral seleccionado fue aproximadamente 0.34. Al congelarlo y aplicarlo sobre test, el recall aumentó hasta 0.7243, pero la FPR también subió hasta 0.1491. El resultado confirmó que el umbral no debe entenderse como un parámetro puramente técnico: desplaza de forma directa el compromiso entre sensibilidad y falsas alarmas.

Tabla 7: Full384 con umbral 0.5 y con el umbral seleccionado en validación.

Métrica	$\tau = 0,50$	$\tau \approx 0,34$
Balanced Accuracy	0.7989	0.7876
Precision	0.9019	0.8571
Recall	0.6906	0.7243
F1	0.7822	0.7851
FPR	0.0927	0.1491

Por tanto, aunque reducir el umbral permite recuperar más positivos, no se adoptó ese resultado como argumento para afirmar que el sistema es simplemente “mejor”. En una aplicación de vigilancia el coste de una falsa alarma y el coste de una detección tardía son distintos, y el punto de operación debería fijarse en función del contexto real de despliegue.

13.3. Sobreajuste y selección del checkpoint

Durante algunas configuraciones se observó una separación clara entre la pérdida de entrenamiento y la de validación. Full30c constituye un ejemplo representativo: la pérdida de entrenamiento siguió descendiendo mientras la de validación empeoraba. El fenómeno no implica que el modelo dejase de

clasificar correctamente de forma inmediata, porque la entropía cruzada también penaliza la confianza de las predicciones, pero sí indicaba que continuar entrenando no garantizaba una mejor generalización.

Por esta razón, el checkpoint final no se eligió por ser la última época disponible. Se conservaron los estados con mejor comportamiento sobre validación y, cuando procedía, se utilizó early stopping. Esta práctica fue especialmente importante en los entrenamientos de mayor resolución, donde el coste computacional hacía poco razonable prolongar épocas sin evidencia de mejora fuera del conjunto de entrenamiento.

14. Resumen de la evolución experimental

Los primeros experimentos no deben interpretarse como una competición ordenada entre modelos, porque se realizaron en momentos diferentes del desarrollo y algunos utilizaron subconjuntos distintos. Su utilidad fue otra: identificar problemas y decidir qué hipótesis merecía una comparación controlada posterior.

El primer baseline mostró que existía señal discriminativa, aunque a umbral 0.5 el recall era bajo. Al reducir mucho el umbral aumentaba la sensibilidad, lo que confirmó que el modelo había aprendido información útil pero estaba mal calibrado para ese punto de operación. La ampliación inicial del dataset aumentó la diversidad de escenas, pero dejó visible el problema de falsas activaciones. La introducción de ResNet18 y mayor resolución mejoró de forma apreciable el comportamiento, aunque todavía no era posible atribuir la mejora de forma limpia al cambio de arquitectura o resolución porque los benchmarks no coincidían por completo.

También se probaron hard negatives extraídos de errores de validación. La idea era exponer al modelo a nubes, bruma u otras escenas que habían generado falsos positivos. El resultado no produjo una mejora clara. La experiencia fue útil porque mostró que concentrar el entrenamiento en una colección pequeña de errores difíciles puede introducir un sesgo excesivo y no sustituye a disponer de un conjunto negativo amplio y representativo.

Una prueba con EfficientNet-B0 tampoco superó las mejores configuraciones basadas en ResNet18. A partir de ese momento se decidió fijar ResNet18 como backbone y centrar el esfuerzo en variables con una hipótesis más directamente relacionada con el problema: resolución espacial, información local y modelización temporal.

Tabla 8: Resumen cualitativo de las principales etapas exploratorias previas a los experimentos finales.

Etapas	Cambio principal	Lección obtenida
MVP1	Primer clasificador binario	Existía señal útil, pero el comportamiento dependía fuertemente del umbral.
MVP2	Más secuencias	El recall podía crecer sin mejorar el comportamiento global por el aumento de falsos positivos.
MVP3	ResNet18 y mayor resolución	La preservación de detalle parecía prometedora, pero era necesario comparar sobre un benchmark común.
MVP4	Recortes locales	Las regiones locales recuperaban señal débil, aunque una agregación ingenua era demasiado sensible.
MVP5	Hard negatives	Añadir errores difíciles de forma manual no garantizaba una mejora estable.
EfficientNet-B0	Backbone alternativo	El cambio de arquitectura por sí solo no resolvía los principales errores.
Full30c	Baseline controlado	Permitió fijar una referencia reproducible para estudiar resolución y temporalidad.

Esta evolución condujo a una metodología más estricta. Las decisiones posteriores se formularon como preguntas concretas y se intentó modificar una única variable relevante cada vez. El estudio de Full224 frente a Full384 es el ejemplo más claro de esta transición desde una fase exploratoria a una fase comparativa

controlada.

15. Bootstrap pareado: procedimiento e interpretación

El bootstrap se utilizó para responder a una pregunta que las métricas puntuales no resuelven: si una diferencia entre dos modelos se mantiene cuando cambia la composición de eventos del conjunto de test. Con 50 eventos, una mejora agregada podría depender de unos pocos incendios especialmente fáciles para un modelo. El remuestreo permite medir hasta qué punto ocurre esto.

En cada réplica se seleccionaron 50 eventos con reemplazo a partir de los 50 disponibles. Un mismo incendio puede aparecer varias veces y otros pueden no aparecer. Después se incluyen todos los frames correspondientes a los eventos seleccionados y se calcula la métrica. En una comparación pareada, Full224 y Full384 reciben exactamente la misma réplica; solo después se calcula la diferencia entre sus métricas. Este proceso se repitió 10 000 veces.

El carácter pareado es importante. Si cada modelo se evaluase sobre una réplica distinta, parte de la diferencia observada se debería simplemente a que uno habría recibido incendios más difíciles. Al mantener la misma muestra para ambos, la distribución resultante describe de forma más directa la variabilidad de la diferencia de rendimiento.

Para Balanced Accuracy, Full384 obtuvo una mejora puntual de 0.0539 y el intervalo bootstrap quedó completamente por encima de cero. Para FPR ocurrió lo contrario: la diferencia fue negativa y el intervalo quedó completamente por debajo de cero, lo que favorece a Full384 porque en esta métrica un valor menor es mejor. En recall, F1 y AUC los intervalos incluyeron cero. Estos últimos resultados no invalidan las diferencias puntuales, pero impiden describirlas con el mismo grado de robustez.

A nivel de evento individual, Full384 obtuvo mejor Balanced Accuracy en 26 incendios, Full224 en 14 y se produjeron 10 empates. Este resultado es coherente con el bootstrap: el modelo de mayor resolución no gana en todos los casos, pero la mejora agregada tampoco depende exclusivamente de uno o dos eventos excepcionales.

16. Detalle del bloque temporal

16.1. Por qué una media móvil es un baseline razonable

La salida de Full384 puede presentar oscilaciones entre frames consecutivos. Si una imagen aislada recibe una probabilidad alta por una nube o un cambio de iluminación, un sistema que aplicase directamente un umbral frame a frame podría generar una alarma puntual. La media móvil introduce una forma sencilla de persistencia: para que la señal suavizada sea alta, la evidencia debe mantenerse durante varias observaciones o alcanzar valores suficientemente elevados de forma repetida.

La regla de cinco observaciones se seleccionó en validación después de comparar alternativas de detecciones consecutivas y ventanas de distinto tamaño. No fue una regla perfecta: ningún criterio probado ofrecía a la vez máxima detección temprana y ausencia de activaciones previas. La elección representa un compromiso razonable y, sobre todo, constituye un baseline transparente frente al que comparar un modelo temporal aprendido.

La métrica “cobertura post- $t = 0$ ” no significa que el sistema detecte el evento exactamente en $t = 0$. Indica la proporción de incendios en los que aparece al menos una alerta en algún instante posterior a la referencia. Las métricas de 300, 600, 900 y 1800 s describen cuánto de esa cobertura se alcanza progresivamente durante los primeros minutos.

La región *clear-pre* se utiliza como aproximación a falsas activaciones claramente anteriores al evento. No debe interpretarse como una tasa de falsas alarmas horaria, porque FgLib no contiene vigilancia continua. Su utilidad es comparar dos estrategias temporales sobre los mismos eventos en una zona donde la activación debería ser improbable.

16.2. Qué aprende la GRU

La GRU no recibe las imágenes. Recibe una secuencia compacta derivada de Full384. El valor p_t informa del nivel actual de evidencia visual, Δp_t indica si esa evidencia está creciendo o disminuyendo y Δt_t permite representar separaciones temporales no necesariamente idénticas entre frames.

A diferencia de la media móvil, la GRU no asigna de forma fija el mismo peso a las observaciones recientes. Mediante sus compuertas puede conservar o descartar información del estado anterior y aprender patrones como una subida progresiva, una señal alta persistente o un pico aislado. Para una GRU estándar, la actualización puede resumirse mediante las compuertas $z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$ y $r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$; el nuevo estado combina el estado previo con una propuesta calculada a partir de la entrada actual. En este anexo no se reproduce toda la derivación matemática porque el objetivo es documentar el diseño experimental, no volver a introducir los fundamentos generales de redes recurrentes.

La ventana de ocho observaciones fija la cantidad de historia reciente disponible en cada decisión. Al ser causal, la predicción en el instante t solo utiliza información hasta ese momento. Esta propiedad es imprescindible para interpretar los resultados como un escenario de alerta en tiempo real.

17. Coste computacional y condicionantes del desarrollo

El aumento de resolución fue una mejora útil, pero tuvo un coste directo. Una imagen de 384×384 contiene casi tres veces más posiciones espaciales que una de 224×224 . El tiempo de ejecución de una CNN no crece exactamente en esa misma proporción, pero la memoria y el número de operaciones de las capas convolucionales aumentan de forma importante.

Gran parte del desarrollo se ejecutó en Google Colab, con acceso temporal a GPU. La disponibilidad no fue constante y algunas sesiones se interrumpieron o quedaron limitadas a CPU. Para mantener los entrenamientos a resolución 384 se redujo el batch físico y se utilizó acumulación de gradiente. Estas restricciones influyeron en el número de épocas y en la amplitud de la búsqueda de hiperparámetros que podía realizarse.

Por este motivo no se exploró de forma sistemática un rango amplio de resoluciones, backbones o combinaciones de hiperparámetros. El trabajo priorizó comparaciones motivadas por errores observados y experimentos que pudieran mantenerse suficientemente controlados. Esta decisión limita la afirmación de optimalidad: Full384 es la mejor configuración de referencia entre las comparadas en condiciones adecuadas, no una demostración de que sea la arquitectura óptima posible para FgLib.

18. Líneas de continuación específicas del módulo

La primera extensión necesaria sería evaluar el sistema sobre vigilancia negativa prolongada. Para un despliegue real interesa conocer falsas alarmas por hora o por día, no únicamente FPR sobre frames seleccionados alrededor de incendios conocidos. Este benchmark debería contener cambios normales de iluminación, niebla, nubes, bruma y estaciones del año completas sin eventos.

La segunda línea consiste en estudiar la generalización geográfica. Un conjunto de cámaras geolocalizadas en España permitiría evaluar si el comportamiento se mantiene bajo vegetación, relieve, ópticas y condiciones atmosféricas diferentes. También permitiría relacionar la salida visual con el módulo meteorológico del TFM sobre el mismo territorio y el mismo intervalo temporal.

En tercer lugar, podría explorarse una integración espacial y temporal más estrecha. En el trabajo actual Full384 y la GRU están deliberadamente separados, lo que facilita la interpretación y el entrenamiento. Un modelo espaciotemporal end-to-end podría aprender conjuntamente qué regiones visuales y qué patrones temporales son relevantes, aunque exigiría más datos, más cómputo y un protocolo de evaluación especialmente cuidadoso.

Por último, sería razonable estudiar resoluciones superiores a 384, técnicas de atención espacial o mecanismos de detección/localización que complementen la clasificación global. Los resultados obtenidos

sugieren que preservar señal pequeña es importante, pero cualquier aumento de sensibilidad debe seguir evaluándose junto con las falsas alarmas.

19. Conclusiones del anexo

El trabajo sobre F1gLib permitió construir un módulo visual-temporal capaz de pasar de una imagen panorámica a una señal de alerta a nivel de evento. La separación por incendio fue una decisión metodológica central para evitar que la correlación entre frames produjese una evaluación artificialmente optimista.

En la parte visual, el resultado más sólido fue el efecto de la resolución. Full384 mejoró la Balanced Accuracy y redujo aproximadamente a la mitad los falsos positivos respecto a Full224. El experimento multiescala confirmó que las regiones locales contienen señal útil, pero también mostró que aumentar sensibilidad puede deteriorar de forma importante la especificidad.

En la parte temporal, la media móvil de cinco observaciones proporcionó un baseline sencillo y conservador. La GRU aprendió a utilizar la evolución de la probabilidad visual y consiguió detectar más eventos y hacerlo antes: la cobertura post- $t = 0$ pasó del 88 % al 96 % y la mediana del retraso se redujo de 361 a 210.5 s. Esta mejora se obtuvo a costa de aumentar las activaciones en la región pre-evento.

Por tanto, el resultado principal del módulo no es una cifra aislada, sino una secuencia de decisiones que permiten controlar distintos tipos de error: mayor resolución para conservar señal visual, evaluación explícita de falsas alarmas y modelización temporal para aprovechar la persistencia del humo. Dentro de la arquitectura global del TFM, este módulo aporta evidencia visual y temporal que puede combinarse con el riesgo meteorológico y el contexto documental, sin asumir que las salidas de todos los componentes constituyan una única probabilidad calibrada.

Referencias

Referencias

- [1] A. Dewangan, Y. Pande, H.-W. Braun, F. Vernon, I. Perez, I. Altintas, G. W. Cottrell y M. H. Nguyen, “F1gLib & SmokeyNet: Dataset and Deep Learning Model for Real-Time Wildland Fire Smoke Detection”, *Remote Sensing*, vol. 14, no. 4, p. 1007, 2022. doi: 10.3390/rs14041007.
- [2] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk y Y. Bengio, “Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation”, en *Proceedings of EMNLP 2014*, pp. 1724–1734, 2014. doi: 10.3115/v1/D14-1179.