

Anexo A. Predicción diaria del riesgo de incendio

Este anexo amplía el módulo de predicción de la memoria en cinco apartados: los datos y su análisis exploratorio (A.1), los modelos construidos y la elección del algoritmo (A.2), la escala del mapa publicado (A.3), las limitaciones (A.4) y el repositorio con la reproducción del trabajo (A.5).

A.1 Datos y análisis exploratorio

Las decisiones de diseño del segundo modelo salen de tres propiedades de los datos: el fuego es muy escaso, las celdas quemadas están agrupadas y el FWI (*Fire Weather Index*) no significa lo mismo en todo el territorio. Este apartado describe las fuentes y las variables, y después mide esas tres propiedades.

A.1.1 Fuentes

La tabla 1 recoge las fuentes empleadas y el uso de cada una. La principal es IberFire [6], un datacubo público de 1 km y un día de resolución que integra 261 variables de libre acceso para la España peninsular y Baleares. Las demás aportaron las etiquetas, la meteorología de servicio o una segunda referencia durante el desarrollo.

Tabla 1. Fuentes de datos, resolución y uso en el trabajo.

Fuente	Qué aporta	Resolución y periodo	Uso
IberFire	261 variables diarias: meteorología, vegetación, relieve, usos del suelo, población y carreteras	1 km; 2008–2024; 29 GB	Variables de entrenamiento de los dos modelos
EGIF (vía Civio)	Punto y fecha de inicio de cada incendio	Registro consolidado hasta 2020	Etiqueta del primer modelo: 19,561 pares celda-día de 2015 a 2020
EFFIS	Perímetros de superficie quemada cartografiados por satélite	Incendios de al menos 5 ha; 2008–2026	Etiqueta del segundo modelo y referencia de todas las evaluaciones
ERA5-Land	Reanálisis meteorológico	Unos 9 km; 5,605 nodos sobre España	Meteorología observada en servicio, hasta siete días antes
IFS (vía Open-Meteo)	Previsión meteorológica	Los mismos nodos; hasta el día siguiente	Meteorología del día y del siguiente; entradas de la reproducción
AEMET	Observación horaria	687 estaciones; verano de 2026	Meteorología de la producción del primer modelo
FIRMS (NASA)	Focos térmicos del sensor VIIRS	Punto; casi tiempo real	Fuego reciente en el entorno de la celda
Partes del MITECO	Incidentes con medios del Estado	Municipio; diario	Segunda referencia durante el desarrollo

EGIF es la Estadística General de Incendios Forestales; EFFIS, el *European Forest Fire Information System*; IFS, el *Integrated Forecasting System*; AEMET, la Agencia Estatal de Meteorología; FIRMS, el *Fire Information for Resource Management System*, y MITECO, el Ministerio para la Transición Ecológica y el Reto Demográfico.

Antes de construir ninguna variable se comprobó de dónde procede la meteorología del cubo. Es ERA5-Land remuestreado: la temperatura, la humedad y el viento coinciden con el reanálisis nativo con correlaciones entre 0.987 y 0.998 y sin sesgo. Solo difiere la precipitación, que en el cubo está dividida por 2.02, y el FWI del cubo corresponde a las 13 UTC. La cadena de servicio aplica el mismo factor y calcula el FWI a esa hora, de modo que el modelo recibe en servicio la misma escala con la que se entrenó.

En el repositorio: [01_datos/README.md](#), [01_datos/cubo/](#).

A.1.2 Malla y variables

El territorio se divide en 498,530 celdas de 1 km. En servicio, cada celda toma la meteorología del nodo de ERA5-Land que la contiene, sin interpolar (figura 1). Los 226 nodos costeros sin dato, un 4.0 % del total, heredan el valor del nodo terrestre más cercano.

(a) 5,605 nodos; cada cuadro, el área de uno



(b) detalle de 90 × 90 km




Figura 1: Malla de servicio. (a) Los 5,605 nodos de ERA5-Land sobre España; cada cuadro del damero es el área de celdas de 1 km que toma su meteorología de un mismo nodo. (b) Detalle de 90 × 90 km alrededor de Madrid, con cada nodo en el centro de sus celdas.

Los dos modelos usan las mismas 46 variables por celda y día, agrupadas en seis familias (tabla 2). Todas las ventanas temporales terminan el día anterior al que se predice, salvo las variables del propio día.

Tabla 2. Las 46 variables del modelo servido y del r10, por familias.

Familia	Variables	N.º
Meteorología del día	Temperatura máxima y mínima, humedad relativa mínima, viento máximo, precipitación, déficit de presión de vapor máximo, temperatura de la superficie terrestre, FWI absoluto, FWI en percentil respecto a la historia de la celda y anomalía tipificada del FWI	10
Meteorología acumulada	Precipitación de 7, 15 y 30 días; FWI medio de 7, 15 y 30 días y máximo de 7 días; medias de 7 días de humedad mínima, temperatura máxima y viento máximo; días sin lluvia	11
Vegetación y suelo	NDVI (<i>Normalized Difference Vegetation Index</i>) del día y medio de 30 días, índice de área foliar y humedad superficial del suelo	4
Territorio	Elevación, pendiente, rugosidad, distancia a carreteras y a ríos, densidad de población y seis clases de uso del suelo: bosque, matorral, agrícola, agrícola heterogéneo, artificial y abierto	12
Historial y focos	Incendios a 10 km en el mismo mes de años anteriores; potencia radiativa máxima y número de focos a 50 km en los siete días previos; rayos del día y de siete días	5
Calendario y región	Mes, día del año, festivo y comunidad autónoma	4

El primer modelo se entrenó con 50 variables. Antes de ponerlo en producción se retiraron cuatro recuentos de incendios en la propia celda, porque el muestreo en la misma celda filtraba en ellos el orden temporal: el incendio del positivo entraba en el historial de los negativos posteriores. Retirarlos costó 0.015 de AUC-PR (*Area Under the Precision-Recall Curve*).

En el repositorio: [01_datos/era5land/malla_01_nodos.py](#), [01_datos/comun/features.py](#).

A.1.3 La escasez del fuego

El fuego es un suceso raro, y esa rareza condiciona cómo se muestrea y cómo se evalúa. Según EFFIS, en verano arden entre 0.50 y 37.96 celdas de cada 100,000 al día, según el año, frente al 25 % de positivos que tenía por construcción el conjunto de la primera iteración (figura 2a). Solo el 2.97 % de las celdas registró alguna ignición de la EGIF entre 2015 y 2020, y el 2.68 % tuvo superficie quemada según EFFIS entre 2021 y 2024.

La etiqueta de EFFIS, además, persiste. Una celda que arde un día sigue marcada al siguiente con probabilidad 0.51, a los tres días con 0.23 y a los siete con 0.04 (figura 2b), porque marca los días en que la celda está ardiendo y no solo el de la ignición. Por eso todas las evaluaciones cuentan el primer día de cada celda quemada: en los veranos evaluados quedan 7,301 de las 28,135 celdas-día marcadas.




Figura 2: (a) Celdas-día con fuego por cada 100,000 según EFFIS, año completo y verano, en escala logarítmica, frente a la proporción de positivos del primer diseño. (b) Probabilidad de que una celda siga marcada como quemada k días después.

En el repositorio: [02_eda/README.md](#), [02_eda/ANALISIS_CUBO.md](#).

A.1.4 La agrupación espacial

Las celdas quemadas están juntas porque proceden de perímetros. El índice de Moran de las celdas de EFFIS entre 2021 y 2024 es 0.81 a 1 km. Con esa autocorrelación, una partición aleatoria pone en el conjunto de prueba celdas vecinas de las de entrenamiento y aumenta artificialmente el AUC (*Area Under the ROC Curve*) en 0.036 frente a una partición por bloques de 100 km. Por ello todas las particiones del trabajo son espaciales o temporales.

En el repositorio: [02_eda/README.md](#).

A.1.5 Qué es el FWI

El FWI es el índice final del sistema canadiense de peligro meteorológico de incendio [7], que EFFIS emplea como índice de referencia para Europa. Se calcula con cuatro observaciones tomadas al mediodía: temperatura, humedad relativa, velocidad del viento y precipitación de las veinticuatro horas anteriores. Con ellas mantiene tres códigos de humedad del combustible muerto, que se secan a ritmos distintos: la hojarasca fina responde en horas, la capa intermedia tarda semanas y la materia orgánica profunda, meses. Los dos primeros, junto con el viento, dan un índice de propagación inicial, y el segundo y el tercero, un índice del combustible disponible; el FWI combina ambos. Es adimensional y no tiene tope: cuanto más alto, más favorable es el tiempo a que un incendio prenda y avance. Que el índice tenga memoria de meses es lo que permite distinguir un día caluroso aislado de otro igual de caluroso al final de una sequía larga.

Importa también lo que el índice no sabe. El FWI describe el tiempo, no el terreno: ignora la vegetación de la celda, su relieve y la presencia de actividad humana, que está detrás de la mayoría de las igniciones en España. Resume bien la componente meteorológica del peligro, pero por sí solo no ordena el territorio, y su lectura depende además del lugar, como se ve a continuación.

A.1.6 El FWI según el lugar

Un mismo valor del FWI indica peligros distintos según la zona. En los días de incendio, el FWI mediano va de 3 en Asturias y Cantabria a 41 en Andalucía (figura 3a), de modo que ningún umbral absoluto sirve para toda la península. Expresado como percentil respecto a la historia de cada celda, el mismo dato se concentra entre 72 y 92 en las ocho comunidades con más incendios (figura 3b). Añadir el percentil al FWI absoluto aumentó el AUC-PR del modelo meteorológico de 0.668 a 0.710.




Figura 3: FWI en los días de incendio del periodo de entrenamiento, por comunidad autónoma. (a) Valor absoluto. (b) Percentil respecto a la historia de la propia celda.

En el repositorio: [02_edu/ANALISIS_CUBO.md](#), [04_bisagra/README.md](#).

A.1.7 Qué separa los días con fuego

En el conjunto de entrenamiento de la primera iteración, con 13,577 positivos y 39,986 negativos, la meteorología separa los dos grupos y las variables del territorio no (figura 4). La mediana del percentil local del FWI es 84 en los positivos y 47 en los negativos; la de los días sin lluvia, 9 frente a 2. La densidad de población y la distancia a carreteras tienen la misma mediana en los dos grupos. Es lo esperable en un diseño que compara cada celda consigo misma en otros días, y anticipa el problema que se describe en A.2.3.




Figura 4: Medianas de positivos y negativos en el conjunto de entrenamiento de la primera iteración (2015–2018). Las variables meteorológicas separan los dos grupos; las del territorio coinciden.

En el repositorio: [02_edu/eda_dataset.py](#), [docs/MEMORIA/figs/scripts/f3_separacion.py](#).

A.1.8 Dos etiquetas que miden cosas distintas

La EGIF registra el punto de ignición de cada incendio y EFFIS el perímetro quemado a partir de 5 ha. Coinciden poco en la misma celda y el mismo día: solo el 2.6 % de las igniciones de 5 a 25 ha, el 14.6 % de las de 25 a 100 ha, el 34 % de las de 100 a 500 ha y el 59 % de las de más de 500 ha tienen su celda marcada por EFFIS ese día. La mediana de la EGIF es de 3.6 ha y el 38 % de sus igniciones se produce entre febrero y abril. Entrenar con igniciones y evaluar con perímetros compara dos magnitudes distintas, y por eso el segundo modelo cambió de etiqueta.

Detalle en el repositorio: las fuentes en [01_datos/README.md](#) y el análisis exploratorio completo en [02_edu/ANALISIS_CUBO.md](#).

En el repositorio: [02_edu/ANALISIS_CUBO.md](#), [04_bisagra/44_es_la_especificacion/](#).

A.2 Modelos: qué se construyó y por qué

Este apartado justifica la elección del algoritmo, describe los modelos de las dos iteraciones y la pregunta que responde cada uno, y compara los seis candidatos sobre las temporadas de 2025 y 2026.

A.2.1 Por qué XGBoost

Todos los modelos del trabajo son XGBoost [2], una implementación de árboles de decisión con *gradient boosting*. La elección responde a la forma de los datos. Las 46 variables son tabulares y heterogéneas: temperaturas, proporciones de uso del suelo, recuentos de incendios y categorías como la comunidad autónoma, con escalas muy distintas y sin necesidad de normalizarlas. Hay valores ausentes, por ejemplo en los focos de satélite, que el algoritmo trata sin imputarlos. El riesgo depende de interacciones no lineales entre la meteorología y el territorio, que los árboles recogen sin especificarlas. El entrenamiento con millones de celdas-día cabe en un ordenador personal, y los valores SHAP (*SHapley Additive exPlanations*) de un conjunto de árboles se calculan de forma exacta, lo que permitió comprobar en qué variables se apoya el modelo.

La bibliografía respalda esta elección para datos de este tipo. En una comparación sobre 45 conjuntos tabulares, los modelos de árboles superaron a las redes neuronales profundas en conjuntos de tamaño medio [3]. Otra comparación de modelos profundos recientes con XGBoost llegó a una conclusión similar [4]. Un estudio con 176 conjuntos encontró que las diferencias entre ambas familias suelen ser pequeñas, pero que los árboles con *boosting* ganan con claridad cuando las variables tienen distribuciones sesgadas o de cola larga [5], como ocurre aquí con la precipitación, los recuentos de incendios o la densidad de población.

Para comprobarlo con los datos del trabajo se comparó XGBoost con la regresión logística, Random Forest y LightGBM. Los cuatro algoritmos se entrenaron con el conjunto del r10 y las mismas 46 variables, con los años de 2015 a 2022 para entrenar, 2023 para elegir la configuración y 2024 para la prueba, y con el mismo presupuesto de ajuste: seis configuraciones por algoritmo. Después se evaluaron en la reproducción de las temporadas de 2025 y 2026 con la previsión de la víspera, igual que el r10. En todos los casos se midió el AUC medio dentro del día, y el protocolo quedó escrito antes de ejecutar.

En la prueba de 2024, Random Forest y LightGBM superaron a la receta del r10 por 0.028 y 0.024 (tabla 3). Esa ventaja no se mantuvo en las temporadas (tabla 4). LightGBM quedó por debajo del r10 en 2025 y empató en 2026. Random Forest empató en las dos, con diferencias de +0.003 y +0.014 cuyos intervalos incluyen el cero. La regresión logística perdió 0.043 en 2025 y 0.070 en 2026, lo que confirma que los árboles aportan frente a un modelo lineal. Elegir la configuración con 2023 tampoco anticipó el resultado: el XGBoost ajustado de esa forma perdió frente a la receta original en 2024 y en 2025.

Con estos resultados no hay motivo para cambiar de algoritmo. XGBoost empata con la mejor alternativa en las dos temporadas y ya estaba en servicio, con sus valores SHAP calculados y su entrenamiento reproducido.

Tabla 3. Comparación de algoritmos con los datos, las 46 variables y la evaluación del r10. AUC medio dentro del día en la prueba de 2024 (72 días con fuego), con su intervalo de confianza al 95 % por remuestreo de días. La diferencia es la media pareada día a día frente a XGBoost con la receta del r10, y los días ganados, el porcentaje de días en que cada algoritmo lo supera. Cada algoritmo, salvo la referencia, usa la mejor de seis configuraciones según el AUC de 2023.

Algoritmo	AUC 2024 [IC 95 %]	Diferencia [IC 95 %]	Días ganados	Entrenamiento
XGBoost, receta del r10	0.805 [0.769, 0.839]	—	—	2.7 s
XGBoost ajustado	0.786 [0.747, 0.822]	−0.019 [−0.037, −0.002]	44 %	3.2 s
LightGBM	0.829 [0.798, 0.859]	+0.024 [+0.007, +0.043]	64 %	4.4 s
Random Forest	0.833 [0.800, 0.864]	+0.028 [+0.008, +0.049]	62 %	23.8 s
Regresión logística	0.803 [0.766, 0.838]	−0.001 [−0.029, +0.025]	47 %	2.2 s

Tabla 4. Los mismos algoritmos en la reproducción de las temporadas de 2025 (138 días con fuego) y 2026 (86 días), con la previsión de la víspera y los perímetros de EFFIS. AUC medio dentro del día sobre todas las celdas de España. La diferencia es la media pareada día a día frente al r10 servido, con su intervalo de confianza al 95 % por remuestreo de días, y los días ganados, el porcentaje de días en que cada algoritmo lo supera.

Algoritmo	2025			2026		
	AUC	Diferencia [IC 95 %]	Días	AUC	Diferencia [IC 95 %]	Días
XGBoost, r10 servido	0.807	—	—	0.762	—	—
XGBoost ajustado	0.783	−0.024 [−0.037, −0.013]	33 %	0.749	−0.012 [−0.033, +0.008]	41 %
LightGBM	0.789	−0.018 [−0.029, −0.008]	41 %	0.748	−0.014 [−0.030, +0.003]	40 %
Random Forest	0.811	+0.003 [−0.010, +0.017]	54 %	0.775	+0.014 [−0.003, +0.032]	52 %
Regresión logística	0.765	−0.043 [−0.065, −0.019]	39 %	0.692	−0.070 [−0.097, −0.044]	26 %

En el repositorio: [05_iteracion2/57_ablaciones/dos_35_algoritmos.py](#), [05_iteracion2/57_ablaciones/dos_35_replay.py](#), [docs/TRAZABILIDAD.md](#).

A.2.2 Primera iteración: la escalera de modelos base

El primer modelo siguió el diseño de presencia y ausencia habitual en la literatura de ocurrencia de incendios [1]: los positivos fueron las igniciones registradas por la EGIF y los negativos, la misma celda en otros días sin incendio, tres

por cada positivo.

Se evaluó con una escalera de referencias, en la que cada peldaño debía superar al anterior (figura 5). Con el conjunto de prueba de 2020 y una proporción de positivos del 26.28 %, el FWI sin modelo obtuvo un AUC-PR de 0.488, un XGBoost solo con el FWI 0.491, uno con toda la meteorología 0.716 y el modelo completo con 50 variables 0.843. Dos controles descartaron fallos del procedimiento. Con las etiquetas barajadas, el AUC-PR cayó a 0.231, cerca de la proporción de positivos (0.263). Con validación cruzada por bloques espaciales de 100 km se mantuvo en 0.848 ± 0.028 . El ajuste bayesiano de hiperparámetros añadió 0.007. La versión entrenada con la EGIF consolidada y probada en 2022 obtuvo el AUC de 0.89 que cita la memoria (0.8906, IC95 [0.8644, 0.9136]).




Figura 5: AUC-PR en el conjunto de prueba de 2020 de cada peldaño de la primera iteración, del FWI sin modelo al XGBoost con 50 variables. La línea discontinua marca el azar, que en esta métrica coincide con la proporción de positivos.

En el repositorio: [03_iteracion1/README.md](#), [03_iteracion1/MODELO_B_BITACORA.md](#).

A.2.3 Por qué falló en operación

En la muestra de la primera iteración, el 98.8 % de las celdas tenía exactamente un 25 % de días con fuego. Con esa proporción fija, el modelo solo podía aprender qué día es peligroso en una celda, y no qué celda es más peligrosa que otra. La métrica de laboratorio no detectaba el problema (figura 6): dos modelos entrenados con cada diseño obtuvieron el mismo AUC, 0.92, medido cada uno con su propio conjunto de prueba, y medidos dentro de cada día obtuvieron 0.744 y 0.828. En operación, con la previsión del día, el modelo obtuvo 0.642 y el percentil local del FWI sin modelo 0.702, una diferencia de -0.060 con un IC95 $[-0.149, +0.020]$ que incluye el cero.




Figura 6: Los dos diseños de muestreo bajo dos métricas. El AUC caso-control, medido con el conjunto de prueba de cada diseño, es igual para los dos; el AUC dentro del día, en el conjunto de prueba de 2020, los separa.

En el repositorio: [04_bisagra/README.md](#).

A.2.4 Los modelos de la segunda iteración

La segunda iteración cambió de dónde salen los negativos y qué se etiqueta como positivo, y mantuvo las 46 variables y los hiperparámetros para que cualquier mejora se pudiera atribuir al diseño. Sobre esa base se construyeron los modelos de la tabla 5, cada uno para responder una pregunta concreta.

Tabla 5. Modelos comparados, qué cambia en cada uno y qué pregunta responde. Todos son XGBoost con las mismas variables e hiperparámetros.

Modelo	Qué cambia	Qué pregunta responde y por qué se construyó
Producción	Negativos de la misma celda en otros días; etiqueta EGIF	«¿Es hoy un día peligroso en esta celda?». Es el modelo de la primera iteración y sirve de referencia
Único 1:3	Negativos de otras celdas el mismo día, tres por positivo; etiqueta EFFIS	«¿Cuál de las celdas arde hoy?», la pregunta de operación planteada directamente
r10	Igual que el único, con diez negativos por positivo	La misma pregunta; se construyó para medir si ver más celdas sin fuego sitúa mejor los incendios grandes
Dónde	Una fila por celda, sin meteorología; etiqueta EFFIS	«¿Esta celda es propensa al fuego?». Su mapa es el mismo todos los días
Cuándo	Solo variables dinámicas; negativos de la misma celda en otros días	«¿Hoy es un día peligroso?», sin información del territorio
Pareja	Producto de los modelos dónde y cuándo	Si separar el territorio y el día en dos modelos interpretables ordena mejor que un modelo único

La cantidad de negativos se estudió con una escalera anidada de 1:3, 1:10, 1:30, 1:60 y 1:100 negativos por positivo, en la que los negativos de cada peldaño contienen a los del anterior. En 2026 el AUC medio apenas cambió, entre 0.745 y 0.759, del orden del ruido del sorteo de celdas (0.004). El percentil de las celdas quemadas ponderado por hectáreas fue máximo con 1:10 (81.9 frente a 79.5 con 1:3) y bajó a partir de 1:30. Por eso se eligió el r10.

En el repositorio: [05_iteracion2/README.md](#).

A.2.5 Comparación de los seis modelos en dos temporadas

La reproducción de las temporadas de 2025 y 2026 comparó los seis modelos con la previsión disponible cada víspera, según un protocolo escrito antes de ejecutarla. La tabla 6 reúne las métricas de ordenación y las de superficie.

Tabla 6. Comparación de los seis modelos con la previsión de la víspera. AUC: media por día. Días: porcentaje de días en que el modelo supera a producción. Pctl. ha: percentil medio de las celdas quemadas ponderado por hectáreas. Ha 2 % y ha 10 %: porcentaje de la superficie quemada de la temporada que cayó en el 2 o el 10 % de celdas de mayor riesgo de cada día. Inc. 10 %: incendios de al menos 100 ha con alguna celda en ese 10 %.

Modelo	AUC	Diferencia (IC 95 %)	Días (%)	Pctl. ha	Ha 2 %	Ha 10 %	Inc. 10 %
<i>Temporada 2025: 138 días con fuego, 386,855 ha</i>							
Producción	0.743	—	—	84.6	22.0	59.6	66.9
Único 1:3	0.806	+0.063 [+0.026, +0.102]	61	87.5	28.8	63.6	67.6
r10	0.807	+0.064 [+0.027, +0.101]	60	86.7	26.3	63.0	69.6
Pareja	0.794	+0.051 [+0.024, +0.079]	60	90.2	32.3	72.4	73.0
Dónde solo	0.744	+0.001 [−0.043, +0.046]	43	87.3	27.5	63.0	56.1
Cuándo solo	0.686	−0.057 [−0.071, −0.043]	24	79.1	16.1	49.6	56.8
<i>Temporada 2026: 86 días con fuego, 267,566 ha</i>							
Producción	0.658	—	—	68.4	11.5	24.7	40.6
Único 1:3	0.757	+0.099 [+0.058, +0.141]	69	76.5	5.9	25.1	59.4
r10	0.762	+0.104 [+0.065, +0.144]	67	77.9	7.1	37.0	62.3
Pareja	0.716	+0.058 [+0.025, +0.089]	58	74.6	2.2	23.7	58.5
Dónde solo	0.701	+0.043 [−0.008, +0.094]	55	68.6	1.1	11.3	39.6
Cuándo solo	0.614	−0.044 [−0.064, −0.025]	28	67.2	6.1	22.5	31.1

En ordenación, los dos modelos únicos encabezan las dos temporadas y empatan entre sí. La pareja supera a producción, pero queda por debajo del modelo único; el modelo de dónde por separado no se distingue de producción, y el de cuándo queda por debajo. Las métricas de superficie no siempre siguen al AUC: en 2025 la pareja situó más hectáreas que el r10 en el 2 y en el 10 % de celdas, y en 2026 producción situó más hectáreas en el 2 % (11.5 frente a 7.1 %), aunque el r10 la superó en el 10 % (37.0 frente a 24.7 %). Esa superficie de 2026 se concentra en pocos días: sin el 23 de julio, que sumó 21,348 ha, la captura de producción en el 2 % baja del 11.5 al 4.8 %.

La figura 7 muestra la distribución día a día que hay tras las medias. En 2025 el primer cuartil de producción es 0.621 y el del r10 0.736, y producción queda por debajo del azar 16 días frente a 7. En 2026 el primer cuartil es 0.517 en producción y 0.690 en el r10, con 19 días bajo el azar frente a 3. La ventaja del r10 procede sobre todo de los días en que producción ordena peor.




Figura 7: AUC dentro del día de los seis modelos en los días con fuego de cada temporada, con la previsión de la víspera. Caja: cuartiles y mediana; bigotes: 1.5 veces el rango intercuartílico. La cifra sobre cada caja es la media de la tabla 6; la línea de puntos, el azar.

En el repositorio: [06_comparacion/README.md](#), [docs/REPLAY_VEREDICTO.md](#).

A.2.6 Territorio vigilado y superficie cubierta

A un gestor le interesa qué parte de la superficie quemada cae dentro de la zona señalada, según el tamaño de esa zona. La tabla 7 lo recoge para el r10. El *lift* es el cociente entre el porcentaje de hectáreas dentro de la zona y el porcentaje de territorio vigilado; un *lift* de 1 equivale a señalar celdas al azar.

Tabla 7. Captura del r10 según el territorio vigilado cada día. Hectáreas: superficie quemada que cayó en la zona vigilada, redondeada a la centena. Inc.: incendios de al menos 100 ha con alguna celda dentro.

Vigilado	2025 (386,855 ha)				2026 (267,566 ha)			
	Ha (%)	Hectáreas	Inc. (%)	Lift	Ha (%)	Hectáreas	Inc. (%)	Lift
1 %	18.6	72,000	23.7	18.6	3.4	9,000	18.9	3.4
2 %	26.3	101,800	32.4	13.2	7.1	19,100	25.5	3.6
5 %	47.5	183,800	53.4	9.5	17.9	47,900	42.5	3.6
10 %	63.0	243,700	69.6	6.3	37.0	99,000	62.3	3.7
20 %	78.7	304,600	83.8	3.9	58.8	157,400	79.3	2.9

En 2025, vigilar el 2 % del territorio cada día habría cubierto el 26.3 % de la superficie quemada, 13.2 veces lo esperable al azar, y el 10 % habría cubierto el 63.0 %. En 2026 la curva es más plana, con un *lift* de 3.7 casi constante hasta el 10 %. Estas hectáreas no son superficie evitada: miden cuánto fuego cayó en la zona señalada, que es el máximo que una vigilancia reforzada allí podría haber anticipado.

En el repositorio: [docs/REPLAY_CAPTURA.md](#), [06_comparacion/captura_lift.py](#).

A.2.7 Alternativas descartadas

La tabla 8 resume las pruebas con resultado negativo. Entrenar solo con verano quita al modelo de dónde información sobre qué territorio arde. Apagar las celdas ya quemadas penaliza porque EFFIS mantiene marcada la celda mientras el incendio sigue activo. Reentrenar con todos los años no alcanzó el criterio fijado por escrito, y la partición original conserva un año de prueba reservado.

Tabla 8. Alternativas evaluadas y no adoptadas. Diferencia de AUC medio por día respecto a la configuración de referencia de cada prueba.

Alternativa	Resultado
Entrenar solo con verano (junio a septiembre)	El modelo de dónde de verano perdió entre -0.011 y -0.041 en cuatro conjuntos de prueba; el de cuándo no cambió
Apagar las celdas quemadas en los 7 a 60 días previos	Entre -0.016 y -0.027 en la temporada de 2026, para producción y para el modelo único, con cualquier ventana
Reentrenar el r10 con 2015–2024 (un 32 % más de positivos)	$+0.0033$, IC95 $[-0.0042, +0.0104]$, sobre 224 días; no cumplió el criterio de éxito fijado antes de ejecutar

Detalle en el repositorio: los modelos y las alternativas en [05_iteracion2/README.md](#) y las tablas completas de la reproducción en [docs/REPLAY_VEREDICTO.md](#).

En el repositorio: [docs/R10_TODOS_LOS_ANIOS.md](#), [05_iteracion2/57_ablaciones/](#).

A.3 Escala absoluta y cifra del día

Los dos mapas y la cifra que se publican cada día salen de la misma puntuación del r10. El primer mapa la ordena por percentil del día; el segundo la corta en niveles fijos, y la cifra sitúa el día entre los de referencia.

Los cortes se calcularon primero con los diez años del cubo, de modo que el nivel extremo fuese el 2 % más alto de su historia. Aplicados a los mapas de la cadena de servicio, marcaron entre dos y diez veces más celdas en extremo que el cubo en el mismo mes. La causa está en el cálculo de las variables de vecindad en servicio (apartado A.4). Por ello los cortes publicados se obtuvieron de los propios mapas servidos, los 250 días de 2025 y 2026 de la reproducción (tabla 9). En el nivel extremo ardió una de cada 760 celdas-día, 13.17 veces la media.

Tabla 9. Niveles del r10 con los cortes del servicio, sobre los 250 días de referencia. Una de cada: celdas-día por cada celda quemada. Factor: frecuencia de quema del nivel dividida entre la media.

Nivel	Corte servicio	Corte cubo	Celdas-día (%)	Quemadas	Una de cada	Factor	Ha (%)
BAJO	0	0	30.0	282	132,600	0.08	1.5
MODERADO	0.0060	0.0018	60.0	5,255	14,200	0.71	40.0
ALTO	0.1125	0.0736	8.0	3,609	2,760	3.63	29.5
EXTREMO	0.4058	0.4066	2.0	3,273	760	13.17	29.0

La cifra del día es el porcentaje de España en nivel extremo, situado entre los 250 días de referencia, en los que la mediana es el 1.5 %, el percentil 90 el 4.6 % y el máximo el 7.2 %. Como indicador de los días con incendio grande (al menos cinco celdas nuevas quemadas), obtuvo un AUC de 0.69 en 2025 y de 0.66 en 2026, frente a 0.74 y 0.44 del calendario.

Antes de la cifra se evaluó un semáforo nacional que retiraba el nivel extremo los días de puntuación baja. En verano perdió uno de cada tres días con incendio grande: el 31.7 % en los diez años del cubo, el 34.6 % fuera del periodo de calibración (2022–2024) y el 54.4 % en la reproducción de 2026. Se compararon cuatro variantes y ninguna se adoptó. La puntuación tampoco es una probabilidad por celda: calibrada con regresión isotónica sobre el cubo, la celda de mayor riesgo en diez años no supera el 1.6 % de probabilidad de arder ese día. Por eso el mapa publica niveles y no probabilidades.

Detalle en el repositorio: [07_produccion/escala_y_cifra/README.md](#).

En el repositorio: [07_produccion/escala_y_cifra/README.md](#), [07_produccion/escala_servicio.json](#).

A.4 Limitaciones

La tabla 10 resume las limitaciones conocidas, con su efecto medido y su consecuencia. La más relevante es que la evaluación de las dos temporadas es a posteriori: los mapas usan la previsión de cada víspera, pero se generaron todos a la vez en septiembre de 2026. La mitigan el protocolo escrito antes de ejecutar, la presentación de los seis modelos y la evaluación de 2026 con reanálisis, hecha antes y por otra vía, que apunta en la misma dirección (+0.112, IC95 [+0.074, +0.151]).

Tabla 10. Limitaciones conocidas del trabajo.

Limitación	Efecto medido	Consecuencia
Evaluación a posteriori	Mapas generados en septiembre de 2026 con las entradas de cada víspera	Mitigada por el protocolo escrito antes de ejecutar
Defecto del viento en el ranking por estaciones	FWI hundido en el 16.3 % de las estaciones-día del verano de 2026	Afecta a las cifras de operación del primer modelo, no a la reproducción
Filtro de vecinos distinto al entrenar y al servir	Tres variables entre un 36 y un 54 % mayores en servicio	Cambia la escala, no el orden; afecta igual a todos los modelos
Variables de satélite del día	Un 4 % de la importancia del r10	Se sustituyen por su climatología mensual en servicio
Ruido del sorteo e intervalos	Sorteo: 0.004 de AUC; intervalos 1.35 veces más estrechos que con bloques de 14 días	Los IC son una cota inferior de la incertidumbre
Escala absoluta en servicio	Cortes calibrados con 250 días de temporada	Sin datos de diciembre a abril; recalcular al acumular días
Etiquetas	EFFIS omite incendios pequeños y tarda unos 45 días	Las etiquetas de 2026 aún pueden cambiar
Datos que cambian con el tiempo	El reanálisis se corrige y EFFIS revisa perímetros durante semanas	Las cifras de la cadena diaria no se regeneran idénticas (A.5.4)
Cobertura	Península y Baleares; 2026 hasta el 2 de septiembre	Sin Canarias, Ceuta ni Melilla

En el repositorio: [docs/LIMITACIONES.md](#).

A.5 Repositorio, trazabilidad y reproducibilidad

Este apartado indica dónde está el trabajo, cómo se comprueba cada cifra y qué hace falta para repetirlo. La reproducción completa es posible, pero requiere días por el volumen de los datos y por los límites de los servicios de

los que se descargan.

A.5.1 Repositorio

El código y la documentación están en un repositorio público, github.com/JuanUtrilla/tfm-riesgo-incendios, con 186 scripts de Python. Las carpetas siguen el orden de la memoria (tabla 11) y cada una tiene un fichero `README.md` que indica qué hace cada script y para qué se usó.

Tabla 11. Organización del repositorio.

Carpeta	Contenido
00_marco/	Hilo del trabajo, glosario y diagrama de las dos iteraciones
01_datos/	Descarga y tratamiento de las fuentes; las 46 variables en <code>comun/features.py</code> (A.1)
02_eda/	Análisis exploratorio del cubo y del conjunto de entrenamiento (A.1)
03_iteracion1/	Muestreo, entrenamiento y puesta en producción del primer modelo (A.2.2)
04_bisagra/	Diagnóstico de la diferencia entre el acierto de laboratorio y el de operación (A.2.3)
05_iteracion2/	Modelos de la segunda iteración, alternativas y calibración (A.2.4, A.2.7)
06_comparacion/	Reproducción de las temporadas de 2025 y 2026 (A.2.5, A.2.6)
07_produccion/	Cadena diaria, escala del servicio y cifra del día (A.3, A.5.5)
docs/	TRAZABILIDAD.md, LIMITACIONES.md, REPLAY_VEREDICTO.md y bitácora
muestras/	Recorte de julio de 2026 (48 MB) con las capas estáticas, el modelo servido y la malla

En el repositorio: [README.md](#), [docs/ESTRUCTURA.md](#).

A.5.2 Trazabilidad

El documento [docs/TRAZABILIDAD.md](#) permite comprobar cualquier cifra del trabajo. Para cada una de las 82 cifras que recoge indica qué script la produjo, en qué fichero quedó escrita y qué datos hacen falta para volver a calcularla. La tabla 12 agrupa esas cifras según lo que necesitan. El documento incluye también los protocolos de evaluación, con la fecha y la hora en que se escribieron, antes de ejecutar las pruebas que describen.

Tabla 12. Cifras de [docs/TRAZABILIDAD.md](#) según los datos que hacen falta para volver a calcularlas.

Tipo	Cifras	Qué hace falta
Muestra	2	Solo el repositorio recién clonado
Cubo	41	El cubo IberFire (29 GB)
Disco	33	El cubo y los conjuntos de entrenamiento generados a partir de él
Sellado	6	No se regeneran: las produjo la cadena diaria contra servicios en vivo en una fecha concreta, y los resultados quedaron guardados

Todos los entrenamientos citados se repitieron en una copia aislada el 2 de septiembre de 2026, con el entorno fijado en `environment.yml` (XGBoost 3.2.0). Las métricas coincidieron sin ninguna discrepancia y los modelos resultantes fueron idénticos a los originales según su huella MD5. El modelo servido en 2026, que se había reentrenado de forma interactiva, se reconstruyó árbol a árbol a partir de la receta documentada.

En el repositorio: [docs/TRAZABILIDAD.md](#).

A.5.3 Qué se puede repetir y cuánto tarda

Repetir el trabajo exige distinguir tres tareas, porque sus requisitos son muy distintos (tabla 13). Comprobar el modelo servido lleva minutos. Entrenar es viable en un ordenador personal si se descarga el cubo. Predecir un día o repetir una temporada exige descargar datos de servicios externos, y esas descargas son las que alargan la reproducción a varios días.

Tabla 13. Tareas de reproducción, requisitos y motivo de su duración.

Tarea	Qué hace falta	Duración y motivo
Comprobar el modelo servido	Clonar el repositorio y ejecutar <code>verificar_v2.py</code>	Minutos; se comprobó en una copia limpia el 15 de septiembre de 2026
Entrenar los modelos	El cubo IberFire (29 GB, en Zenodo) y ejecutar los scripts en orden	La descarga del cubo y el cómputo; no depende de ningún servicio externo
Predecir un día	Reanálisis ERA5-Land de los 5,605 nodos y previsión IFS	La API de Copernicus sirve por cola, de 20 a 30 min por fichero; bajar 72 meses de reanálisis supone unas 30 h. Open-Meteo impone cuotas diarias y por hora: el 15 de septiembre de 2026, calcular un solo día alcanzó el tope horario y quedó 53 min a la espera
Repetir las temporadas	El archivo de previsiones de cada víspera y los perímetros de EFFIS	Hay que reconstruir el archivo, y EFFIS revisa los perímetros durante semanas

Para entrenar el r10 desde el cubo, con el cubo en la variable de entorno TFM_DATOS y los conjuntos intermedios en TFM_USB, los scripts de la segunda iteración se ejecutan en este orden:

1. `dos_01_celdas.py`: tabla por celda.
2. `dos_12_muestrear_effis.py`: tabla maestra con etiqueta EFFIS.
3. `dos_03_features.py`: variables de cada celda-día.
4. `dos_13_modelos_effis.py`: modelos único, dónde y cuándo.
5. `dos_18_ratio.py` muestrear, `dos_03_features.py` ratio y `dos_18_ratio.py` modelos: escalera de negativos y r10.

El primer modelo sigue la misma lógica con `muestrear_dataset.py`, `extraer_features_cubo.py`, `extraer_features_historia`, `ensamblar_dataset.py` y `entrenar_modelo.py`.

En el repositorio: [README.md](#), [environment.yml](#), [muestras/README.md](#).

A.5.4 Cadena diaria

La prueba de que el sistema funciona fuera del ordenador del equipo es la cadena diaria. GitHub Actions, el servicio de ejecución automática de GitHub, la ejecuta cada día desde cero, sin acceso al cubo, y la corrida dura alrededor de una hora y cuarto, casi toda en la descarga del reanálisis y de la previsión (figura 8). El estado que se conserva entre corridas se guarda en una publicación del propio repositorio, y cada día se generan los mapas de hoy y de mañana con la cifra del día. Cada corrida redibuja también los mapas de los veinte días anteriores con los perímetros de EFFIS y los incidentes del MITECO ya conocidos. En los trece primeros días de septiembre de 2026, con el nivel extremo entre el 0.2 y el 1.6 % de España, cayó en él el 22 % de las celdas quemadas del día y el 37 % de los incidentes del MITECO.




Figura 8: Pasos de la cadena diaria en GitHub Actions. En cursiva, la fuente o el producto de cada paso. CDS es el *Climate Data Store* de Copernicus.

En el repositorio: [.github/workflows/mapa_diario.yml](#), [07_produccion/README.md](#).

Referencias

- [1] Rodrigues, M. y de la Riva, J. (2014). An insight into machine-learning algorithms to model human-caused wildfire occurrence. *Environmental Modelling & Software*, 57, 192–201. <https://doi.org/10.1016/j.envsoft.2014.03.003>
- [2] Chen, T. y Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>
- [3] Grinsztajn, L., Oyallon, E. y Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? En *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*.
- [4] Shwartz-Ziv, R. y Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion*, 81, 84–90. <https://doi.org/10.1016/j.inffus.2021.11.011>
- [5] McElfresh, D. et al. (2023). When Do Neural Nets Outperform Boosted Trees on Tabular Data? En *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*.
- [6] Ercibengoa Calvo, J., Gómez-Omella, M. y Goienetxea Urkizu, I. (2025). IberFire: a detailed creation of a spatio-temporal dataset for wildfire risk assessment in Spain. arXiv:2505.00837. Datos: <https://doi.org/10.5281/zenodo.15225885>
- [7] Van Wagner, C. E. (1987). *Development and structure of the Canadian Forest Fire Weather Index System*. Forestry Technical Report 35. Canadian Forestry Service, Ottawa.