



UNIVERSIDAD COMPLUTENSE MADRID

UNIVERSIDAD COMPLUTENSE DE MADRID

Máster en Big Data, Data Science e Inteligencia Artificial

Anexo C

Índice

1. Objetivos	1
2. Conjunto de datos D-Fire	1
2.1. Estructura encontrada	1
2.2. Creación de validation	2
2.3. Clases	2
3. Modelo visual	3
3.1. YOLO11	3
3.2. Modelo baseline	3
4. Evaluación del modelo baseline	3
4.0.1. Average Precision y mAP	3
4.1. Resultados globales	5
4.2. Resultados por clase	5
5. Análisis de errores	5
5.1. Matriz de confusión	5
5.2. Análisis detallado de errores	6
5.3. Evaluación de presencia de fuego y humo	8
5.4. Influencia del tamaño de los objetos	9
5.5. Influencia del número de objetos por imagen	11
5.6. Influencia del umbral de confianza	12
5.7. Análisis conjunto de confianza y NMS	14
6. Experimento de resolución: 640×640 frente a 960×960	16
6.1. Configuración del modelo 960	16
6.2. Resultados globales sobre test	17
6.3. Resultados por clase	17
6.4. Objetos pequeños	18
6.5. Número de objetos por imagen	19
6.6. Análisis de errores del modelo 960	19
6.7. Evaluación de presencia de fuego y humo	20
6.8. Barrido del umbral de confianza	20
6.9. Experimento conjunto de confianza y NMS para 960	21
6.10. Evaluación específica de fuego en validation	22
6.11. Coste computacional e inferencia	24
6.12. Selección de la configuración	24

7. Discusión de los resultados y conclusiones	25
8. Referencias	26

1. Objetivos

1. Preparar y analizar un conjunto de datos de imágenes de fuego y humo.
2. Desarrollar un modelo de detección de objetos basado en YOLO11.
3. Evaluar el modelo mediante métricas de detección de objetos.
4. Analizar falsos positivos y falsos negativos.
5. Experimentar con distintas estrategias de mejora del modelo visual.
6. Comparar el rendimiento de diferentes modelos.
7. Analizar el compromiso entre capacidad de detección, falsas alarmas y coste computacional.

2. Conjunto de datos D-Fire

Para desarrollar esta fase se ha seleccionado el conjunto de datos **D-Fire**, desarrollado por GAIA Solutions on Demand. El repositorio oficial proporciona imágenes orientadas a la detección de fuego y humo y anotaciones en formato YOLO.

D-Fire contiene más de 21.000 imágenes y contempla imágenes con fuego, humo, fuego y humo, y ejemplos sin estos objetos. El conjunto proporciona 14.692 bounding boxes de fuego y 11.865 de humo.

2.1. Estructura encontrada

El conjunto extraído localmente presenta la siguiente estructura:

```
extracted/  
|-- train/  
|   |-- images/  
|   '-- labels/  
'-- test/  
    |-- images/  
    '-- labels/
```

Los datos disponibles fueron:

Conjunto	Imágenes
Train	17.221
Test	4.306
Total	21.527

Cuadro 1: Distribución original encontrada.

Se comprobó que todas las imágenes de train y test disponían de su correspondiente archivo de anotación.

2.2. Creación de validation

Para disponer de un conjunto de validación se tomó el 15 % del conjunto train original. Se utilizó una semilla aleatoria fija de 42 para garantizar la reproducibilidad.

Conjunto	Imágenes	Procedencia
Train	14.638	85 % de train original
Validation	2.583	15 % de train original
Test	4.306	Test original
Total	21.527	

Cuadro 2: Distribución utilizada para el entrenamiento.

El conjunto de test se mantuvo separado para realizar la evaluación final. Validation se utiliza para seleccionar modelos y configuraciones.

2.3. Clases

Las dos clases utilizadas son:

ID	Clase
0	smoke
1	fire

Cuadro 3: Clases del problema de detección.

Las imágenes sin objetos anotados se conservan como ejemplos de background, ya que permiten al modelo aprender a distinguir humo y fuego de elementos visualmente similares del entorno.

3. Modelo visual

3.1. YOLO11

Se seleccionó la familia YOLO11 de Ultralytics para desarrollar el detector visual. Concretamente se utilizó **YOLO11s** con pesos preentrenados.

El modelo produce, para cada detección, la clase, las coordenadas de la bounding box y un nivel de confianza.

3.2. Modelo baseline

La primera versión se entrenó con una resolución de entrada de 640×640 píxeles.

Arquitectura	YOLO11s
Pesos iniciales	Preentrenados
Resolución	640×640
Épocas	100
Batch size	16
Paciencia	20 épocas
Clases	smoke, fire

Cuadro 4: Configuración principal del baseline.

El objetivo de esta primera fase no es únicamente maximizar la precisión de las cajas delimitadoras, sino establecer una línea base que permita estudiar qué tipos de errores comete el sistema y determinar posteriormente qué aspectos deben mejorarse antes de incorporar la información meteorológica.

4. Evaluación del modelo baseline

La evaluación del detector se realizó utilizando diferentes métricas habituales en problemas de detección de objetos. Se analizaron principalmente la precisión (*Precision*), el *Recall*, el F1-score, AP y mAP.

4.0.1. Average Precision y mAP

En detección de objetos no basta con determinar si una predicción es correcta: también es necesario evaluar si la caja predicha se encuentra correctamente localizada respecto a la caja real. Para ello se utiliza la métrica *Intersection over Union* (IoU):

$$IoU = \frac{Area(B_{pred} \cap B_{gt})}{Area(B_{pred} \cup B_{gt})} \quad (1)$$

donde B_{pred} es la caja predicha por el modelo y B_{gt} la caja real (*ground truth*).

A partir de la relación entre precisión y recall para diferentes umbrales de confianza se obtiene la curva Precision–Recall. El área bajo esta curva se denomina *Average Precision* (AP). La AP se calcula para cada clase y para un determinado umbral de IoU.

La métrica **mAP** (*mean Average Precision*) corresponde a la media de la AP obtenida para todas las clases:

$$mAP = \frac{1}{C} \sum_{c=1}^C AP_c \quad (2)$$

En este trabajo se utilizan principalmente dos variantes:

mAP@0.5. También denominada **mAP50**, considera una predicción como correctamente localizada cuando su IoU con la caja real es, al menos, 0.5. Por tanto, mAP@0.5 mide la capacidad del modelo para detectar correctamente los objetos utilizando un criterio de localización relativamente tolerante.

mAP@0.5:0.95. También denominada **mAP50-95**, calcula la AP utilizando múltiples umbrales de IoU: 0.50, 0.55, 0.60, ..., 0.95, y posteriormente obtiene la media. Por tanto:

$$mAP_{50:95} = \frac{1}{10} \sum_{IoU=0.50}^{0.95} AP_{IoU} \quad (3)$$

Esta segunda métrica es considerablemente más exigente, ya que no basta con detectar el objeto: la caja debe ajustarse con mayor precisión a su localización real.

Por este motivo, una diferencia elevada entre mAP@0.5 y mAP@0.5:0.95 puede indicar que el modelo identifica correctamente la presencia de los objetos, pero presenta dificultades para localizar con precisión sus límites.

En el contexto de este proyecto, esta distinción es especialmente relevante: un sistema de alerta temprana puede ser útil incluso cuando la caja delimitadora no es perfecta, siempre que detecte de forma fiable la presencia de humo o fuego. Por ello, además de las métricas estándar de detección, se realizarán experimentos específicos de presencia/ausencia y análisis de errores.

4.1. Resultados globales

Métrica	Validation	Test
Precision	0.7845	0.7948
Recall	0.7297	0.7300
mAP@0.50	0.7841	0.7858
mAP@0.75	0.4716	0.4619
mAP@0.50:0.95	0.4641	0.4614

Cuadro 5: Resultados globales.

Validation y test presentan resultados muy similares. Esto constituye una primera indicación de que no existe un sobreajuste evidente y que el modelo mantiene un comportamiento relativamente estable ante datos no utilizados durante el entrenamiento.

El mAP@0.50 es cercano a 0.786, mientras que el mAP@0.50:0.95 se reduce hasta aproximadamente 0.461. Esta diferencia indica que, aunque el modelo detecta una proporción razonable de objetos con un criterio IoU de 0.50, la localización de las bounding boxes es menos precisa cuando se utilizan criterios de IoU más exigentes.

4.2. Resultados por clase

Clase	Precision	Recall	F1	AP@0.50	AP@0.50:0.95
Smoke	0.8384	0.8030	0.8203	0.8473	0.5409
Fire	0.7307	0.6564	0.6915	0.7209	0.3873

Cuadro 6: Resultados por clase sobre test.

Existe una diferencia clara entre ambas clases. El modelo presenta un mejor rendimiento en humo: recall de 0.8030 y AP@0.50 de 0.8473. En fuego, el recall es 0.6564 y el AP@0.50 es 0.7209.

Por tanto, el principal punto débil del baseline es la detección de fuego. La diferencia también es importante en AP@0.50:0.95, con 0.5409 para humo frente a 0.3873 para fuego.

5. Análisis de errores

5.1. Matriz de confusión

La matriz de confusión normalizada obtenida para el conjunto de test se muestra en la Figura 1.




Figura 1: Matriz de confusión normalizada del modelo YOLO11s sobre test.

La matriz de confusión del detector permite analizar cómo se distribuyen las predicciones entre las clases *fire*, *smoke* y el fondo.

Es importante interpretar correctamente la categoría “background” en el contexto de detección de objetos. Esta categoría no representa directamente el porcentaje de imágenes de fondo que el modelo clasifica erróneamente como fuego o humo. En su lugar, representa predicciones que no han podido asociarse a una anotación real o anotaciones reales que no han sido detectadas.

El análisis de la matriz muestra que el modelo distingue razonablemente bien entre fuego y humo, mientras que una parte significativa de los errores está relacionada con el fondo. El problema es especialmente acusado para la clase *fire*, que presenta una proporción superior de detecciones no asociadas a objetos reales.

Este resultado motivó un análisis más detallado de los errores para determinar si los problemas observados correspondían principalmente a falsos positivos, duplicación de predicciones, problemas de localización o detecciones perdidas.

5.2. Análisis detallado de errores

Las métricas estándar permiten evaluar el rendimiento global del modelo, pero no permiten conocer directamente qué tipo de error domina las predicciones. Por este motivo se desarrolló un análisis basado en la asociación uno a uno entre predicciones y anotaciones reales.

Para cada imagen se compararon las cajas predichas con las cajas *ground truth* utilizando IoU. Cada objeto real podía ser asociado como máximo a una predicción. De esta forma se evitó contabilizar varias veces una misma anotación, problema que puede producirse en un análisis basado únicamente en el solapamiento.

Las predicciones y anotaciones se clasificaron en las siguientes categorías:

- **TP**: predicción de la clase correcta con IoU suficiente.
- **DUPLICATE**: predicción adicional próxima a un objeto que ya había sido asociado a otra predicción.
- **FP_REAL**: predicción que no puede asociarse a un objeto real.
- **LOCALIZATION_ERROR**: predicción de la clase correcta que presenta cierto solapamiento con el objeto real, pero no alcanza el IoU necesario para considerarse correctamente localizada.
- **FN**: objeto real que no ha sido detectado.
- **CLASS_CONFUSION**: predicción que se solapa con un objeto real pero pertenece a una clase diferente.

El análisis inicial produjo la siguiente distribución:

Categoría	Número	Porcentaje (%)
TP	4016	46.13
DUPLICATE	2133	24.50
FP_REAL	1379	15.84
LOCALIZATION_ERROR	721	8.28
FN	396	4.55
CLASS_CONFUSION	60	0.69

Cuadro 7: Distribución de errores mediante matching uno a uno.




Figura 2: Histograma de los distintos tipos de errores según la clase.

El principal resultado de este análisis es la elevada presencia de predicciones duplicadas. Aproximadamente un 24.5 % de los registros analizados corresponden a predicciones adicionales alrededor de objetos que ya habían sido detectados.

Esto indica que parte importante de los errores observados inicialmente como problemas de localización estaban relacionados en realidad con múltiples predicciones sobre un mismo objeto. Tras aplicar el matching uno a uno, la proporción clasificada como error de localización se reduce al 8.28 %.

No obstante, estos porcentajes deben interpretarse como una distribución de tipos de error del procedimiento de análisis y no como una sustitución de las métricas estándar de precisión y recall, ya que las diferentes categorías utilizan denominadores distintos en las definiciones convencionales de detección.

5.3. Evaluación de presencia de fuego y humo

Dado que el objetivo final del proyecto es desarrollar un sistema de alerta temprana, se consideró relevante estudiar el problema desde una perspectiva diferente a la localización exacta de cada objeto.

En concreto, se evaluó si una imagen contenía o no una determinada clase, independientemente de la precisión de la caja delimitadora. Se consideraron tres escenarios:

1. Presencia de fuego.
2. Presencia de humo.
3. Presencia de fuego o humo.

Los resultados obtenidos fueron:

Escenario	Precision	Recall	F1
Fire	0.9298	0.9740	0.9514
Smoke	0.9344	0.9789	0.9561
Fire OR Smoke	0.9639	0.9861	0.9749

Cuadro 8: Evaluación de presencia/ausencia.

Los resultados son considerablemente superiores a los obtenidos en la evaluación estándar de detección de objetos. Para el caso conjunto de fuego o humo se alcanza un F1 de 0.9749.

Este resultado sugiere que una parte importante de la penalización observada en las métricas de detección está asociada a la localización de las cajas y a la generación de predicciones duplicadas. El modelo parece presentar una capacidad considerablemente mayor para determinar que existe fuego o humo en una imagen que para delimitar con precisión todos los objetos presentes.

Esta diferencia es relevante para el diseño del sistema final. El objetivo de una primera alerta no requiere necesariamente una localización perfecta del incendio, aunque esta información sí resulta importante para etapas posteriores de análisis y localización geográfica.

5.4. Influencia del tamaño de los objetos

Se estudió también la influencia del tamaño de las cajas delimitadoras sobre el rendimiento del detector. Para ello, los objetos se dividieron en tres grupos de tamaño utilizando terciles de la distribución del área relativa de las cajas.

Los percentiles utilizados fueron:

- Percentil 33: 0.4895 % del área de la imagen.
- Percentil 66: 5.3521 % del área de la imagen.

Los resultados de recall fueron:

Tamaño	Fire	Smoke
Small	0.7669	0.7154
Medium	0.7872	0.7720
Large	0.8136	0.8550

Cuadro 9: Recall según el tamaño del objeto.

Se observa una tendencia clara: el recall aumenta con el tamaño del objeto. El efecto es especialmente acusado para la clase *smoke*, cuyo recall pasa de 71.54 % para objetos pequeños a 85.50 % para objetos grandes.




Figura 3: Histograma de recall según el tamaño del obejeto.

También se analizó el IoU medio de las detecciones correctas:

Tamaño	Fire	Smoke
Small	0.6405	0.6901
Medium	0.6757	0.6948
Large	0.7084	0.7648

Cuadro 10: IoU medio según tamaño del objeto.




Figura 4: Histograma de IoU según el tamaño del objeto.

Los resultados muestran que los objetos pequeños son más difíciles tanto de detectar como de localizar con precisión. Esta observación resulta coherente con el objetivo de detección temprana, ya que un incendio en sus primeras etapas puede ocupar una región muy pequeña de la imagen.

Por tanto, la detección de objetos pequeños constituye uno de los principales aspectos susceptibles de mejora en futuras fases del proyecto.

5.5. Influencia del número de objetos por imagen

Además del tamaño individual de los objetos, se analizó si la cantidad de objetos presentes en una imagen afecta al rendimiento del detector.

El recall obtenido en función del número de objetos reales por imagen fue:

Número de objetos	Recall (%)
1	86.01
2–3	82.66
4–5	78.01
6–10	77.61
> 10	71.29

Cuadro 11: Recall según el número de objetos presentes en la imagen.




Figura 5: Histograma del recall según el numero de objetos por imagen.

Existe una disminución progresiva del recall a medida que aumenta el número de objetos. En imágenes con un único objeto se alcanza un recall del 86.01 %, mientras que este valor disminuye hasta el 71.29 % en imágenes con más de diez objetos.

Este comportamiento puede estar relacionado con la presencia simultánea de objetos pequeños o muy próximos entre sí y con las decisiones del algoritmo de supresión de predicciones duplicadas (NMS). Las escenas densamente pobladas constituyen, por tanto, otro escenario especialmente complejo para el modelo.

5.6. Influencia del umbral de confianza

Se estudió también influencia del umbral de confianza utilizado para aceptar las predicciones del modelo.

Se evaluaron valores entre 0.1 y 0.9:

Conf.	Precision	Recall	mAP@0.5	mAP@0.5:0.95
0.1	0.7845	0.7297	0.7504	0.4460
0.2	0.7845	0.7297	0.7271	0.4351
0.3	0.7845	0.7297	0.7066	0.4244
0.4	0.7997	0.7181	0.6728	0.4100
0.5	0.8493	0.6598	0.6239	0.3888
0.6	0.8947	0.5839	0.5586	0.3578
0.7	0.9314	0.4448	0.4309	0.2931
0.8	0.9630	0.2570	0.2496	0.1859
0.9	0.4848	0.0328	0.0320	0.0279

Cuadro 12: Resultados según el umbral de confianza.




Figura 6: Precision-Recall según el umbral de confianza.

Se observa el comportamiento habitual del compromiso entre precisión y recall. Al aumentar el umbral se eliminan predicciones de menor confianza, reduciendo los falsos positivos y aumentando la precisión, pero también se eliminan detecciones potencialmente correctas, reduciendo el recall.

A partir de un umbral de 0.5 la pérdida de recall comienza a ser especialmente importante. Para un sistema de alerta temprana no resulta conveniente optimizar exclusivamente la precisión, ya que el coste de un falso negativo puede ser mayor que el de una falsa alarma.

Por este motivo, los valores de confianza bajos o moderados, aproximadamente entre 0.2 y 0.4, aparecen como candidatos más adecuados para posteriores experimentos.

5.7. Análisis conjunto de confianza y NMS

El análisis anterior mostró que el umbral de confianza tiene una influencia considerable sobre el equilibrio entre detecciones correctas, falsos positivos y falsos negativos. Por otro lado, el análisis de errores mostró que una proporción importante de las predicciones corresponde a duplicados.

Por este motivo se realizó un experimento conjunto modificando dos parámetros:

- Umbral de confianza: 0.1, 0.2, 0.3, 0.4, 0.5 y 0.6.
- Umbral IoU del NMS: 0.3, 0.4, 0.5, 0.6 y 0.7.

En total se evaluaron 30 configuraciones.

El objetivo fue determinar cómo afectan ambos parámetros a la distribución de errores obtenida mediante el procedimiento de matching uno a uno.




Figura 7: Precision-Recall según el umbral de confianza y NMS.

Los principales resultados se muestran en la Tabla 5.7.

Conf.	NMS	TP (%)	Dup. (%)	FP (%)	Loc. (%)	FN (%)
0.1	0.3	58.94	7.22	16.74	9.97	6.40
0.1	0.4	56.75	10.23	16.56	9.75	5.99
0.1	0.5	54.20	13.69	16.31	9.48	5.61
0.1	0.6	50.94	18.20	16.00	9.01	5.11
0.1	0.7	46.13	24.50	15.84	8.28	4.55
0.2	0.3	64.41	3.97	10.42	10.15	10.34
0.2	0.4	63.47	5.28	10.38	10.13	10.04
0.2	0.5	61.95	7.33	10.31	10.02	9.67
0.2	0.6	60.05	9.90	10.24	9.72	9.32
0.2	0.7	57.16	13.86	10.08	9.36	8.80
0.3	0.3	65.93	2.36	6.82	9.20	14.97
0.3	0.4	65.60	2.89	6.80	9.27	14.73
0.3	0.5	64.88	3.94	6.76	9.29	14.38
0.3	0.6	63.94	5.25	6.74	9.15	14.10
0.3	0.7	62.33	7.57	6.64	8.95	13.70
0.4	0.3	64.76	1.33	3.99	7.68	21.53
0.4	0.4	64.66	1.51	3.99	7.72	21.42
0.4	0.5	64.46	1.81	3.97	7.73	21.30
0.4	0.6	64.01	2.50	3.95	7.67	21.11
0.4	0.7	63.43	3.37	3.94	7.62	20.83
0.5	0.3	60.31	0.69	2.17	5.52	30.70
0.5	0.4	60.27	0.75	2.17	5.52	30.68
0.5	0.5	60.21	0.86	2.17	5.53	30.63
0.5	0.6	60.01	1.17	2.16	5.53	30.49
0.5	0.7	59.80	1.56	2.15	5.51	30.35
0.6	0.3	52.27	0.44	1.08	3.55	42.22
0.6	0.4	52.26	0.46	1.08	3.55	42.21
0.6	0.5	52.25	0.47	1.08	3.55	42.20
0.6	0.6	52.22	0.53	1.08	3.54	42.18
0.6	0.7	52.13	0.74	1.08	3.54	42.07

Cuadro 13: Experimento conjunto de umbral de confianza y NMS.

El resultado más destacado es que el umbral de confianza tiene una influencia mucho mayor que el parámetro NMS. Al aumentar la confianza disminuyen de forma muy clara los duplicados y los falsos positivos, pero aumenta de forma considerable el número de falsos negativos.

Por ejemplo, utilizando $NMS = 0.3$, el porcentaje de falsos negativos aumenta desde 6.40 % para una confianza de 0.1 hasta 42.22 % para una confianza de 0.6. En paralelo, los falsos positivos disminuyen desde 16.74 % hasta 1.08 %.

El comportamiento del NMS es diferente. Para un mismo umbral de confianza, incre-

mentar el IoU del NMS produce un aumento progresivo de las predicciones duplicadas. Sin embargo, su influencia sobre el recall es mucho menor que la del umbral de confianza.

La configuración con confianza 0.2 y NMS 0.3 presenta un compromiso interesante para un sistema de alerta temprana:

- TP: 64.41 %.
- Duplicados: 3.97 %.
- Falsos positivos: 10.42 %.
- Errores de localización: 10.15 %.
- Falsos negativos: 10.34 %.

Por otro lado, la configuración 0.3/0.3 consigue reducir los falsos positivos hasta el 6.82 % y los duplicados hasta el 2.36 %, pero a costa de aumentar los falsos negativos hasta el 14.97 %.

Por tanto, para el objetivo de detección temprana parece más razonable priorizar inicialmente una configuración próxima a 0.2/0.3 frente a 0.3/0.3, ya que la primera conserva una mayor sensibilidad.

6. Experimento de resolución: 640×640 frente a 960×960

A partir del análisis anterior se identificó el tamaño de los objetos como uno de los principales factores que condicionan el rendimiento del detector. En particular, los objetos pequeños presentan menor recall y peor localización. Dado que la reducción de tamaño de fuego y humo dentro de una imagen puede ser especialmente relevante durante las primeras fases de un incendio, se planteó un segundo entrenamiento de YOLO11s utilizando una resolución de entrada superior, 960×960 píxeles.

El objetivo de este experimento no fue únicamente mejorar el mAP global, sino comprobar si una mayor resolución permite conservar más información espacial y, por tanto, detectar mejor objetos pequeños. Al mismo tiempo, se evaluó el coste computacional adicional de esta configuración.

6.1. Configuración del modelo 960

Se entrenó un segundo modelo YOLO11s manteniendo la arquitectura y el resto de la configuración principal del baseline, modificando la resolución de entrada de 640×640 a 960×960 . De esta forma, la comparación permite atribuir las diferencias principalmente al tamaño de entrada.

Parámetro	640×640	960×960
Arquitectura	YOLO11s	YOLO11s
Pesos iniciales	Preentrenados	Preentrenados
Resolución	640×640	960×960
Épocas	100	100
Batch size	16	16
Clases	smoke, fire	smoke, fire

Cuadro 14: Comparación de las configuraciones de entrada de los dos modelos.

6.2. Resultados globales sobre test

La evaluación del modelo 960 sobre el conjunto de test produjo los siguientes resultados:

Métrica	640×640	960×960	Variación absoluta
Precision	0.7948	0.7891	-0.0057
Recall	0.7300	0.7208	-0.0092
mAP@0.50	0.7858	0.7905	+0.0047
mAP@0.50:0.95	0.4614	0.4690	+0.0076

Cuadro 15: Comparación de las métricas globales de los modelos 640 y 960 sobre test.

El incremento de resolución no produce una mejora sustancial en las métricas globales. La precisión disminuye ligeramente, de 0.7948 a 0.7891, y el recall también disminuye, de 0.7300 a 0.7208. Sin embargo, el mAP@0.50 aumenta de 0.7858 a 0.7905 y el mAP@0.50:0.95 pasa de 0.4614 a 0.4690.

Por tanto, no puede concluirse que 960×960 sea globalmente superior al modelo 640×640. La principal ventaja de la resolución superior aparece al analizar específicamente los objetos de menor tamaño.

6.3. Resultados por clase

Para el modelo 960 se obtuvieron los siguientes valores de AP:

Clase	AP@0.50	AP@0.50:0.95
Smoke	0.8471	0.5361
Fire	0.7340	0.4019

Cuadro 16: AP por clase para YOLO11s 960×960 sobre test.

El comportamiento por clase sigue la tendencia observada en el baseline: el humo resulta más sencillo de detectar que el fuego. No obstante, el AP de fuego a 960×960 aumenta ligeramente respecto al baseline, mientras que el AP de humo permanece prácticamente estable.

6.4. Objetos pequeños

Para estudiar específicamente el efecto de la resolución se utilizaron los mismos umbrales de área relativa empleados anteriormente. Los objetos se dividieron mediante los percentiles 33 y 66 de la distribución del área de las bounding boxes:

- Percentil 33: 0.4895 % del área de la imagen.
- Percentil 66: 5.3521 % del área de la imagen.

Los resultados del modelo 960 fueron:

Clase y tamaño	Recall	IoU medio
Fire - Small	0.8519	0.6628
Fire - Medium	0.9445	0.6988
Fire - Large	0.9505	0.7181
Smoke - Small	0.8848	0.6752
Smoke - Medium	0.9059	0.7049
Smoke - Large	0.9695	0.7729

Cuadro 17: Recall e IoU medio según clase y tamaño para 960×960 sobre test.

El resultado más relevante del cambio de resolución aparece en la detección de objetos pequeños. En el análisis realizado, el recall de fuegos pequeños pasa de aproximadamente 76.7 % con 640×640 a 85.2 % con 960×960 , mientras que el recall de humos pequeños pasa de aproximadamente 71.5 % a 88.5 %.

Esta mejora es especialmente interesante para el objetivo del proyecto, ya que las primeras señales visuales de un incendio pueden ocupar una fracción reducida de la imagen. La resolución superior permite conservar más detalle espacial durante el proceso de detección y favorece la recuperación de estos objetos pequeños.

No obstante, la mejora de recall no implica una localización perfecta. Para fuego pequeño el IoU medio es 0.6628 y para humo pequeño 0.6752. En particular, en humo pequeño el recall aumenta notablemente, mientras que el IoU medio es ligeramente inferior al obtenido con 640×640 . Esto sugiere que la resolución superior permite encontrar más objetos pequeños, aunque algunas de las nuevas detecciones siguen presentando una delimitación imperfecta.

6.5. Número de objetos por imagen

También se repitió el análisis según la densidad de objetos presentes en cada imagen. Para 960×960 se obtuvo:

Número de objetos	Recall (%)
1	84.78
2–3	80.36
4–5	72.59
6–10	75.22
> 10	59.41

Cuadro 18: Recall según el número de objetos para YOLO11s 960×960.

Las escenas densamente pobladas continúan siendo difíciles incluso con la resolución superior. En imágenes con más de diez objetos el recall desciende hasta 59.41 %. Por tanto, aumentar la resolución ayuda especialmente con objetos pequeños, pero no elimina las dificultades asociadas a escenas con muchos objetos simultáneos.

6.6. Análisis de errores del modelo 960

Se aplicó el mismo procedimiento de matching uno a uno utilizado para el baseline, con el objetivo de separar las predicciones correctas de los duplicados, falsos positivos, errores de localización, falsos negativos y confusiones de clase.

Categoría	Número	Porcentaje (%)
TP	4022	46.94
DUPLICATE	1931	22.54
FP_REAL	1301	15.18
LOCALIZATION_ERROR	752	8.78
FN	419	4.89
CLASS_CONFUSION	143	1.67

Cuadro 19: Distribución de errores del modelo 960 mediante matching uno a uno.

El modelo 960 mantiene como principal fuente de error las predicciones duplicadas, aunque su proporción es inferior a la obtenida inicialmente con la configuración 640 y NMS=0.7. También se observa una proporción similar de falsos positivos reales y errores de localización. Los errores de confusión de clase son reducidos en términos globales, aunque aumentan respecto al análisis correspondiente al modelo 640.

El análisis por clase muestra además que el fuego concentra una parte mucho mayor de los falsos positivos y duplicados. Para 960 se contabilizaron 2.121 TP de fuego, 1.229 duplicados, 1.020 falsos positivos reales, 471 errores de localización, 286 falsos negativos y 57 confusiones de clase. En humo se obtuvieron 1.901 TP, 702 duplicados, 281 falsos positivos reales, 281 errores de localización, 133 falsos negativos y 86 confusiones de clase.

6.7. Evaluación de presencia de fuego y humo

Al igual que para el baseline, se evaluó la capacidad del modelo 960 para determinar únicamente si una imagen contiene fuego o humo, sin exigir una localización perfecta de cada objeto.

Escenario	Precision	Recall	F1
Fire	0.9330	0.9749	0.9535
Smoke	0.9365	0.9774	0.9565
Fire OR Smoke	0.9651	0.9848	0.9748

Cuadro 20: Evaluación de presencia/ausencia para YOLO11s 960×960.

Los resultados vuelven a ser muy superiores a las métricas de detección de objetos. El escenario conjunto de fuego o humo alcanza un F1 de 0.9748. Esto refuerza la interpretación planteada para el baseline: una parte relevante de la penalización de las métricas de detección procede de la localización y de las predicciones duplicadas, y no exclusivamente de la incapacidad para reconocer visualmente el fenómeno.

6.8. Barrido del umbral de confianza

Se realizó un barrido de confianza de 0.1 a 0.9 para comprobar si el cambio de resolución modificaba el comportamiento del detector ante distintos umbrales.

Conf.	Precision	Recall	F1	mAP50	mAP50-95
0.1	0.7891	0.7208	0.7534	0.7543	0.4483
0.2	0.7891	0.7208	0.7534	0.7311	0.4358
0.3	0.7891	0.7208	0.7534	0.7007	0.4245
0.4	0.7907	0.7176	0.7523	0.6747	0.4110
0.5	0.8461	0.6600	0.7415	0.6260	0.3882
0.6	0.8917	0.5789	0.7020	0.5522	0.3556
0.7	0.9388	0.4378	0.5971	0.4243	0.2914
0.8	0.9835	0.2149	0.3527	0.2123	0.1625
0.9	0.4861	0.0120	0.0234	0.0122	0.0114

Cuadro 21: Barrido del umbral de confianza para YOLO11s 960×960 sobre test.

El comportamiento es análogo al observado para 640×640: aumentar el umbral mejora la precisión a costa de una pérdida progresiva de recall. Para un sistema de alerta temprana, valores altos como 0.6–0.8 resultan poco adecuados porque eliminan un número considerable de detecciones potencialmente útiles.

Debe señalarse que los valores de mAP mostrados en esta tabla corresponden al procedimiento de evaluación utilizado para cada umbral y no deben interpretarse como una nueva definición de la mAP intrínseca del modelo. Para seleccionar una configuración operativa resultan más apropiados Precision, Recall, F1 y el número de falsos positivos y falsos negativos a un umbral determinado.

6.9. Experimento conjunto de confianza y NMS para 960

Para estudiar de forma más detallada la interacción entre el umbral de confianza y la supresión de predicciones duplicadas, se repitió el experimento 30 configuraciones utilizado anteriormente, combinando seis valores de confianza con cinco valores del IoU del NMS.

Conf.	NMS	TP	Dup.	FP	Loc.	FN
0.1	0.3	59.27	5.89	16.00	10.21	6.95
0.1	0.4	57.03	8.97	15.74	10.03	6.50
0.1	0.5	54.48	12.57	15.43	9.80	6.01
0.1	0.6	51.56	16.40	15.36	9.44	5.54
0.1	0.7	46.94	22.54	15.18	8.78	4.89
0.2	0.3	64.25	3.35	10.19	10.29	10.68
0.2	0.4	63.24	4.82	10.13	10.25	10.31
0.2	0.5	61.93	6.73	10.01	10.19	9.90
0.2	0.6	60.38	8.81	9.97	10.03	9.58
0.2	0.7	57.78	12.38	9.85	9.74	9.02
0.3	0.3	65.37	2.17	6.64	9.16	15.71
0.3	0.4	64.89	2.86	6.62	9.12	15.54
0.3	0.5	64.18	3.92	6.60	9.10	15.22
0.3	0.6	63.45	4.95	6.59	9.06	14.96
0.3	0.7	61.99	7.03	6.50	8.92	14.57
0.4	0.3	64.07	1.32	4.17	8.09	21.57
0.4	0.4	63.81	1.69	4.17	8.05	21.48
0.4	0.5	63.58	2.08	4.15	8.08	21.32
0.4	0.6	63.26	2.55	4.17	8.07	21.16
0.4	0.7	62.52	3.63	4.17	8.03	20.86
0.5	0.3	59.50	0.85	2.42	6.03	30.52
0.5	0.4	59.40	1.02	2.42	6.02	30.47
0.5	0.5	59.30	1.18	2.41	6.01	30.41
0.5	0.6	59.14	1.42	2.43	6.01	30.31
0.5	0.7	58.81	1.97	2.43	6.01	30.08
0.6	0.3	52.61	0.38	1.17	4.02	41.30
0.6	0.4	52.60	0.40	1.17	4.02	41.29
0.6	0.5	52.57	0.45	1.17	4.01	41.27
0.6	0.6	52.55	0.47	1.17	4.01	41.25
0.6	0.7	52.47	0.62	1.17	4.02	41.17

Cuadro 22: Distribución de errores para las 30 configuraciones de confianza y NMS del modelo 960. Los valores se expresan en porcentaje.

La conclusión coincide con el experimento realizado a 640×640 : el umbral de confianza domina claramente el comportamiento del detector. Al incrementar la confianza disminuyen los duplicados y los falsos positivos, pero aumenta de manera acusada el número de falsos negativos.

El parámetro NMS tiene un efecto más limitado. Con confianza fija, aumentar el IoU del NMS tiende a conservar más predicciones próximas entre sí y, por tanto, aumenta la proporción de duplicados. El valor NMS=0.3 es el que produce de forma general menos duplicados dentro de cada nivel de confianza.

Para 960×960 , la configuración 0.2/0.3 obtiene 10.68 % de falsos negativos, 10.19 % de falsos positivos y 3.35 % de duplicados. La configuración 0.3/0.3 reduce los falsos positivos hasta 6.64 % y los duplicados hasta 2.17 %, pero aumenta los falsos negativos hasta 15.71 %. Esto vuelve a mostrar el compromiso entre sensibilidad y falsas alarmas.

6.10. Evaluación específica de fuego en validation

Dado que el fuego constituye la clase más difícil y que el objetivo prioritario es la detección temprana, se realizó un análisis adicional sobre validation, sin utilizar el conjunto de test para seleccionar la configuración operativa. Se utilizó matching uno a uno con IoU mínimo de 0.5 y se analizaron los fuegos pequeños utilizando los mismos umbrales de área definidos anteriormente.

Resol.	Conf.	Precision	Recall	F1	FN	Small Recall	Pred.
640	0.1	0.4644	0.7943	0.5861	367	0.7232	3051
960	0.1	0.4635	0.7999	0.5869	357	0.7479	3079
640	0.2	0.5950	0.7405	0.6598	463	0.6631	2220
960	0.2	0.5896	0.7450	0.6582	455	0.6714	2254
640	0.3	0.6881	0.6827	0.6854	566	0.5830	1770
960	0.3	0.6710	0.6939	0.6823	546	0.6113	1845
640	0.4	0.7586	0.6183	0.6813	681	0.4853	1454
960	0.4	0.7428	0.6362	0.6854	649	0.5289	1528
640	0.5	0.8209	0.5499	0.6586	803	0.3969	1195
960	0.5	0.8035	0.5594	0.6596	786	0.4370	1242
640	0.6	0.8839	0.4524	0.5984	977	0.2898	913
960	0.6	0.8620	0.4518	0.5929	978	0.3027	935

Cuadro 23: Evaluación específica de fuego sobre validation para distintas confianzas y resoluciones.




Figura 8: Comparativa de las métricas de los modelos 640 y 960 según el umbral de confianza.

Los resultados muestran una ventaja consistente de 960×960 en recall de fuego para los umbrales entre 0.1 y 0.5, aunque acompañada normalmente de una ligera reducción de precisión. El efecto es especialmente interesante para fuegos pequeños.

A una confianza de 0.3, por ejemplo, el recall de fuego aumenta de 68.27 % a 69.39 %, mientras que el recall de fuegos pequeños aumenta de 58.30 % a 61.13 %. Además, los falsos negativos pasan de 566 a 546. La mejora se obtiene a costa de una reducción marginal del

F1, de 68.54 % a 68.23 %, y de un incremento de falsos positivos.

A una confianza de 0.4 se obtiene otro resultado relevante: 960×960 alcanza un recall de fuego de 63.62 %, frente a 61.83 % para 640×640, y el recall de fuegos pequeños aumenta de 48.53 % a 52.89 %. El F1 de ambas configuraciones es prácticamente idéntico, aunque el modelo 960 reduce los falsos negativos de 681 a 649.

6.11. Coste computacional e inferencia

El aumento de resolución implica un coste computacional adicional. Para cuantificarlo se realizó un benchmark sobre 500 imágenes, utilizando cinco repeticiones y descartando así la influencia de una única medición aislada.

Métrica	640×640	960×960
Tiempo medio por imagen (ms)	21.51	23.87
FPS	46.50	41.89
Desviación estándar del tiempo total (s)	0.804	0.558

Cuadro 24: Benchmark de inferencia sobre 500 imágenes.

El modelo 960 requiere en promedio 23.87 ms por imagen frente a 21.51 ms para 640×640. Esto supone un incremento aproximado del 10.99 % en el tiempo de inferencia y una reducción del 9.91 % en la tasa de imágenes procesadas por segundo, pasando de 46.50 FPS a 41.89 FPS.

6.12. Selección de la configuración

Considerando conjuntamente los resultados, la resolución 960×960 no puede considerarse superior en todas las métricas. El modelo 640×640 presenta ligeramente mejores valores globales de precisión y recall, mientras que 960×960 ofrece una mejora moderada en mAP y, sobre todo, una mejora notable en la detección de objetos pequeños.

Dado que el objetivo del sistema es la alerta temprana, se considera más relevante evitar la pérdida de indicios visuales de fuego que maximizar la precisión a costa de aumentar los falsos negativos. Bajo este criterio, una configuración candidata es:

- **Modelo:** YOLO11s.
- **Resolución:** 960×960.
- **Confianza:** aproximadamente 0.3.
- **NMS IoU:** aproximadamente 0.3.

La elección de 960×960 se justifica principalmente por su mejor comportamiento ante objetos pequeños y por el coste computacional relativamente moderado observado en el benchmark. En particular, a confianza 0.3 sobre validation, el modelo 960 reduce los falsos negativos de fuego y mejora el recall de fuegos pequeños respecto al modelo 640. El coste adicional medido es de solo un 11 % de tiempo por imagen.

7. Discusión de los resultados y conclusiones

Los diferentes análisis realizados permiten extraer varias conclusiones sobre el comportamiento del modelo.

El experimento de resolución muestra que incrementar la entrada de 640×640 a 960×960 no produce una mejora global suficientemente grande como para justificar el cambio únicamente mediante mAP. Sin embargo, sí existe una ventaja clara en la detección de objetos pequeños, especialmente en el análisis específico de fuego, que resulta más alineada con el objetivo de detección temprana.

En primer lugar, existe una diferencia importante entre la capacidad de detectar la presencia de fuego o humo y la capacidad de localizar exactamente cada objeto. Mientras que el modelo obtiene un F1 de 0.9749 en la tarea de determinar si una imagen contiene fuego o humo, el $\text{mAP}@0.5:0.95$ global es de 0.4614. Esto indica que las métricas de detección están penalizando errores de localización y predicciones duplicadas que no necesariamente implican que el modelo sea incapaz de identificar visualmente el fenómeno.

En segundo lugar, el fuego constituye una clase más difícil que el humo. El recall de fuego es de 0.6564 frente a 0.8030 para humo, y su $\text{mAP}@0.5:0.95$ es 0.3873 frente a 0.5409.

En tercer lugar, el tamaño de los objetos tiene una influencia clara. Los objetos pequeños presentan menor recall y menor IoU medio. Este resultado es especialmente importante para un sistema de detección temprana, dado que los primeros indicios de un incendio pueden aparecer como regiones pequeñas dentro de la imagen.

También se ha comprobado que las imágenes con numerosos objetos presentan mayor dificultad. El recall disminuye desde el 86.01 % para imágenes con un único objeto hasta el 71.29 % para imágenes con más de diez objetos.

Finalmente, el experimento conjunto de confianza y NMS muestra que el principal factor de control del comportamiento del detector es el umbral de confianza. Un aumento excesivo de este parámetro reduce los falsos positivos, pero produce una pérdida demasiado elevada de recall. Para un sistema de alerta temprana, este comportamiento sugiere que debe evitarse optimizar únicamente la precisión.

En conjunto, estos resultados apoyan una estrategia en la que el detector visual se utilice como primera fuente de evidencia para generar alertas, mientras que información adicional, como las variables meteorológicas planteadas en la segunda fase del proyecto,

pueda utilizarse posteriormente para aportar contexto y ayudar a reducir falsas alarmas.

8. Referencias

- [1] GAIA Solutions on Demand. *D-Fire Dataset*. Repositorio oficial. <https://github.com/gaia-solutions-on-demand/DFireDataset>
- [2] Ultralytics. *YOLO11 Documentation*. <https://docs.ultralytics.com/models/yolo11/>