



UNIVERSIDAD COMPLUTENSE DE MADRID

Máster en Big Data, Data Science e Inteligencia Artificial

**Sistema multimodal para la detección temprana
de incendios forestales mediante
inteligencia artificial**

Trabajo Fin de Máster

Autores

Daniel Bravo Quintián
Alejandro Carrasco Ordejón
Pablo Medina de la Iglesia
Juan Peñas Utrilla
Antón Soto Martínez
Adrián Tomás Alonso

Curso académico 2025–2026

Índice

1. Introducción y objetivos	1
2. Arquitectura global y fuentes de datos	1
2.1. Arquitectura general	1
2.2. Datos meteorológicos	2
2.3. Fuente visual D-Fire	2
2.4. Fuente visual-temporal FFigLib/HPWREN	3
2.5. Corpus documental MITECO	3
2.6. Trazabilidad y reproducibilidad	4
3. Modelización meteorológica	4
3.1. Objetivo del módulo	4
3.2. Datos y variables utilizadas	5
3.3. Primer modelo: entrenamiento y evaluación en operación	5
3.4. Segundo modelo: mismo algoritmo, distinta pregunta	6
3.5. Resultados, límites y conclusiones	7
4. Visión artificial y detección temporal	9
4.1. Detección espacial mediante YOLO11	9
4.2. Influencia del tamaño de los objetos	10
4.3. Número de objetos por imagen	10
4.4. Clasificación visual sobre FFigLib	11
4.5. Efecto de la resolución	12
4.6. Información local y estrategias multiescala	12
4.7. De la clasificación visual a la detección temporal	12
4.8. Modelado temporal mediante GRU	13
4.9. Resultados temporales	13
4.10. Síntesis del bloque visual	14
5. Contextualización documental mediante RAG	14
5.1. Construcción y almacenamiento del corpus documental	15
5.1.1. Fuente y actualización del corpus	15
5.1.2. Extracción, snapshots y chunking	15
5.1.3. Embeddings y almacenamiento	16
5.2. Orquestación y ejecución del flujo de consulta	16
5.2.1. Ejecución y estado compartido	17
5.2.2. Preparación e interpretación de la consulta	17
5.2.3. Selección y ejecución de la recuperación	18
5.2.4. Construcción de la respuesta y persistencia	18

5.3. Validación y limitaciones	19
6. Conclusiones	19
6.1. Conclusiones generales	19
6.2. Limitaciones	19

1. Introducción y objetivos

Los incendios forestales constituyen un problema ambiental, económico y social de gran impacto. Su evolución puede ser muy rápida, por lo que la detección temprana es un factor clave para reducir el tiempo de respuesta y facilitar la movilización de recursos.

En los últimos años, las técnicas de aprendizaje automático y visión por computador han permitido desarrollar sistemas capaces de identificar humo o fuego a partir de imágenes. Sin embargo, una única fuente de información presenta limitaciones importantes. El humo incipiente puede ocupar una región muy pequeña de la imagen, mientras que fenómenos como nubes, niebla, bruma o cambios de iluminación pueden generar patrones visualmente similares y provocar falsas alarmas.

Además, el riesgo de incendio está condicionado por factores meteorológicos, de la vegetación, del territorio y de la actividad humana, como la temperatura, la humedad, el viento, los usos del suelo o la densidad de población. Una vez detectado un posible evento, también resulta útil disponer de información documental fiable y actualizada que permita contextualizar la alerta mediante fuentes oficiales.

Por este motivo, el presente trabajo propone una arquitectura modular para la detección temprana y contextualización de incendios forestales mediante técnicas de analítica avanzada e inteligencia artificial. El sistema combina tres tipos principales de información:

- Variables meteorológicas y del territorio para caracterizar las condiciones de riesgo;
- Información visual y temporal para detectar evidencia de humo o fuego;
- Información documental oficial para contextualizar los posibles eventos detectados.

La arquitectura no pretende combinar todas estas fuentes en una única probabilidad, ya que los diferentes módulos se entrenan y evalúan sobre conjuntos de datos distintos. En su lugar, cada componente aporta una evidencia complementaria dentro de un sistema de apoyo a la detección y análisis de incendios.

2. Arquitectura global y fuentes de datos

2.1. Arquitectura general

El sistema se ha diseñado mediante una arquitectura modular en la que cada componente analiza el problema de los incendios forestales desde una perspectiva diferente.

Los módulos principales son:

- Un módulo de predicción que estima el riesgo de incendio a partir de datos meteorológicos, de vegetación y del territorio.
- Un módulo visual basado en el dataset D-Fire para detectar y localizar regiones de fuego y humo.
- Un módulo visual-temporal basado en el dataset FgLib/HPWREN para estimar evidencia de humo y estudiar su evolución a lo largo del tiempo.
- Un módulo RAG para la recuperación de información documental procedente de los partes oficiales del MITECO.

Cada componente se desarrolla y evalúa de forma independiente, ya que utiliza fuentes de datos, objetivos y métricas distintas. Por este motivo, las salidas de los módulos no se combinan mediante una única probabilidad final. En su lugar, se interpretan como fuentes de evidencia complementarias dentro de una arquitectura común de apoyo a la detección y contextualización de incendios.

La Figura 1 resume esta estructura.




Figura 1: Arquitectura general del sistema multimodal. El módulo meteorológico caracteriza las condiciones ambientales; D-Fire permite localizar fuego y humo; FgLib y la GRU incorporan evidencia visual y temporal; y el sistema RAG añade contexto documental procedente de fuentes oficiales.

2.2. Datos meteorológicos

Se emplearon cuatro fuentes, descritas en el Anexo A:

- IberFire, un datacubo público (Tekniker y UPV/EHU, Universidad del País Vasco / Euskal Herriko Unibertsitatea).
- EGIF (Estadística General de Incendios Forestales), el registro oficial de incendios de MITECO.
- EFFIS (European Forest Fire Information System), los perímetros de superficie quemada que Copernicus cartografía por satélite.
- ERA5-Land (ECMWF Reanalysis v5 Land) e IFS (Integrated Forecasting System), ambos del ECMWF (European Centre for Medium-Range Weather Forecasts).

A partir de estas fuentes de datos, se construyen las variables que se introducen en el modelo.

2.3. Fuente visual D-Fire

D-Fire [1] se utiliza para estudiar la detección y localización espacial de fuego y humo. El conjunto contiene más de 21 000 imágenes y anotaciones mediante *bounding boxes* para dos clases: *smoke* y *fire*.

La distribución utilizada se muestra en la Tabla 1.

Tabla 1: Distribución utilizada del conjunto D-Fire.

Conjunto	Imágenes
Train	14 638
Validation	2 583
Test	4 306
Total	21 527

El conjunto de validación se construyó utilizando el 15 % del conjunto de entrenamiento original, con una semilla aleatoria fija, mientras que el conjunto de test se mantuvo separado para la evaluación final.

Este dataset permite entrenar un detector que, para cada imagen, produce tres elementos principales: clase, *bounding box* y confianza.




Figura 2: Imágenes DFire con label y bounding box.

2.4. Fuente visual-temporal FIgLib/HPWREN

FIgLib se utiliza para estudiar la detección de humo mediante cámaras fijas y su evolución temporal. A diferencia de D-Fire, este conjunto está organizado en secuencias asociadas a eventos de incendio.

Cada imagen puede representarse como:

$$(I_t, t) \quad (1)$$

donde I_t representa la imagen capturada en el instante t , y t indica el desplazamiento temporal respecto a una referencia del evento.

Esta estructura permite analizar dos problemas diferentes:

- Clasificación visual de cada frame
- Detección temprana utilizando la evolución de las predicciones

El clasificador visual produce una probabilidad de presencia de humo para cada imagen:

$$p_t = P(\text{humo} \mid I_t) \quad (2)$$

Posteriormente, el modelo temporal utiliza una ventana de observaciones pasadas para generar una señal de alerta.

Para evitar fuga de información entre imágenes altamente correlacionadas, la separación entre entrenamiento, validación y test se realiza a nivel de evento.

2.5. Corpus documental MITECO

El componente documental se construye a partir de los partes diarios publicados por el Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO).

Estos documentos contienen información relacionada con:

- Localización
- Provincia y comunidad autónoma
- Estado del incendio
- Medios desplegados
- Fecha de actualización

Los documentos se procesan y transforman en registros estructurados denominados *snapshots*. Cada snapshot representa el estado documentado de un incendio en una fecha concreta.

Los snapshots se almacenan en formato JSONL y se utilizan posteriormente para construir dos sistemas de consulta complementarios:

- **ChromaDB**, para recuperación semántica combinada con filtros de metadatos;
- **SQLite**, para consultas exactas sobre metadatos.

La utilización de ambos almacenamientos permite diferenciar entre consultas abiertas en lenguaje natural y operaciones que requieren resultados exactos, como recuentos o búsquedas de fechas extremas.

2.6. Trazabilidad y reproducibilidad

Los distintos módulos se han diseñado manteniendo la separación entre entrenamiento, validación y evaluación final.

Los principales elementos complementarios del proyecto se recogen en los anexos de esta memoria. Estos incluyen ejemplos de las fuentes utilizadas, configuraciones, resultados experimentales adicionales, análisis complementarios e información sobre la ejecución de los diferentes módulos. Asimismo, los anexos proporcionan acceso a los repositorios asociados, en los que se conserva el código fuente completo y otros artefactos que, por su extensión, no se incluyen directamente en el documento.

De este modo, la memoria presenta los elementos necesarios para comprender la solución y sus resultados principales, mientras que los anexos y los repositorios indicados en ellos permiten ampliar la información y facilitar la reproducibilidad del trabajo.

3. Modelización meteorológica

3.1. Objetivo del módulo

La España peninsular y Baleares se representan en 498 530 celdas de un kilómetro de lado. El objetivo de este módulo es ordenar cada mañana esas celdas de mayor a menor riesgo de incendio para el día en curso. Su calidad se mide observando si las celdas que ardieron ese día ocupaban las primeras posiciones.

Dentro del sistema conjunto, este módulo cubre el “antes” del incendio. La visión por computador cubre el “durante” y el RAG, el “después”.

El trabajo se desarrolló en dos iteraciones. Un primer modelo alcanzó un AUC (*Area Under the ROC Curve*) de 0.89 en su conjunto de prueba, pero al evaluarlo en operación contra la superficie quemada real su rendimiento se situó entre 0.57 y 0.64. El problema no residía ni en el algoritmo ni en la meteorología, sino en que el modelo respondía a una pregunta distinta de la requerida en operación.

Con el diseño corregido, el segundo modelo pasó de 0.74 a 0.81 en la temporada de 2025 y de 0.66 a 0.76 en la de 2026, evaluado día a día sobre ambas temporadas completas.

3.2. Datos y variables utilizadas

A partir de las fuentes comentadas en el apartado 2.2, se construyen 46 variables por celda y día, agrupadas en cuatro familias principales:

- **Meteorología:** temperatura, humedad, viento, precipitación del día y acumulada en los últimos 7, 15 y 30 días, además del índice FWI (*Fire Weather Index*);
- **Características de la celda:** bosque, matorral, pendiente, altitud, carreteras y población;
- **Historial de fuego del entorno:** incendios ocurridos a 1 y 10 km en meses y años anteriores, así como focos térmicos de satélite en la última semana;
- **Calendario:** día y mes del año.

El análisis exploratorio mostró tres resultados principales.

En primer lugar, el fenómeno presenta una elevada escasez. En la mayoría de los veranos entre 2015 y 2024 se observaron entre 2 y 7 celdas ardiendo por cada 100 000 al día, según los perímetros de EFFIS. Además, solo el 3 % de las celdas registró alguna ignición entre 2015 y 2020 según EGIF.

En segundo lugar, existe una fuerte agrupación espacial. Las celdas quemadas son contiguas al proceder de perímetros de incendio, por lo que una partición aleatoria entre entrenamiento y prueba puede aumentar artificialmente el AUC. Para evitarlo, las particiones del trabajo se realizaron por bloques espaciales de 100 km o por años.

Por último, se observó que el valor absoluto del FWI no tiene el mismo significado en todas las regiones. Un FWI de 40 puede ser habitual en Almería y excepcional en Asturias. Por ello, el FWI se expresa como percentil respecto a la historia de la propia celda. En el conjunto de entrenamiento, la mediana de ese percentil fue de 84 en los días con fuego y de 47 en los días sin fuego.

3.3. Primer modelo: entrenamiento y evaluación en operación

El primer modelo se construyó siguiendo un diseño habitual en la literatura [2] . Los positivos fueron los 19 561 incendios registrados por EGIF entre 2015 y 2020, cada uno asociado a su celda y fecha. Los negativos se seleccionaron en la misma celda durante otros días sin incendio, utilizando tres negativos por cada positivo.

Se entrenó un modelo XGBoost (*eXtreme Gradient Boosting*) y se ajustó con los datos de 2021. La evaluación se realizó sobre 2022, uno de los años con mayor actividad de incendios de la década, obteniéndose un AUC de 0.89.

El modelo no presentaba fugas de información ni una pérdida apreciable de rendimiento al validarlo mediante bloques espaciales de 100 km. El ajuste de hiperparámetros añadió únicamente 0.007 puntos de AUC, por lo que el rendimiento procedía principalmente de las variables utilizadas.

Con este resultado, el modelo se puso en producción en julio de 2026. Cada mañana descarga las observaciones de 687 estaciones de AEMET, calcula las 46 variables y publica un ranking nacional y un mapa de riesgo para el día actual y el siguiente.

La evaluación operativa se realizó frente a tres fuentes independientes: los perímetros de EFFIS, los partes diarios del MITECO y los focos térmicos de satélite. El rendimiento diario del modelo se situó entre 0.57 y 0.64, mientras que el uso aislado del percentil local del FWI ofrecía mejores resultados.

Se estudiaron tres posibles explicaciones:

- **La medida no era el problema.** Las tres fuentes de referencia, procedentes de satélite, cartografía y partes oficiales, coincidían en los positivos principales.
- **La meteorología tampoco explicaba la caída.** El modelo se entrenó con reanálisis y se utilizó en producción con estaciones de AEMET. Aunque existían diferencias entre ambas fuentes, su magnitud no justificaba la pérdida observada.

- **La causa estaba en la formulación del problema.** Al tomar los negativos de la misma celda en otros días, todas las celdas presentaban prácticamente la misma proporción de días con fuego dentro de la muestra. De esta forma, el modelo podía aprender qué día era peligroso para una celda concreta, pero no qué celda era más peligrosa que otra.

En términos prácticos, el modelo respondía a la pregunta: “¿Es hoy un día peligroso en esta celda?”, mientras que en operación se necesitaba responder: “¿Qué celdas presentan mayor riesgo hoy entre las 498 530 disponibles?”.

3.4. Segundo modelo: mismo algoritmo, distinta pregunta

La segunda iteración mantuvo el mismo algoritmo, las mismas 46 variables y la misma malla espacial, pero modificó el diseño del problema de aprendizaje.

En el primer enfoque, cada celda quemada se comparaba consigo misma en otros días. En el segundo, cada celda positiva se compara con otras celdas del mismo día, reproduciendo mejor la pregunta operativa.

La Figura 3 resume ambos diseños.




Figura 3: Comparación entre los dos diseños de muestreo y la pregunta operativa. En el primer diseño, cada celda quemada se compara consigo misma en otros días; en el segundo, se compara con otras celdas del mismo día, reproduciendo la forma en que el modelo se utiliza en operación.

La evidencia de que la formulación era el problema se obtuvo al comparar ambos diseños. Dos modelos entrenados con cada enfoque alcanzaron aproximadamente 0.92 de AUC cuando se evaluaban con conjuntos de prueba contruidos de acuerdo con su propio diseño. Sin embargo, al medir el rendimiento dentro de cada día, de la misma forma en que se utiliza el sistema, obtuvieron 0.744 y 0.828 respectivamente.

La segunda versión modificó dos elementos principales. En primer lugar, los negativos pasaron a ser otras celdas del mismo día. En segundo lugar, la etiqueta pasó a ser la superficie quemada de EFFIS, coincidiendo con la fuente utilizada en la evaluación.

Este cambio respondió a una comprobación previa: solo el 15 % de las igniciones de EGIF de entre 25 y 100 hectáreas coincidía, en la misma celda y fecha, con un perímetro de EFFIS. Entrenar con puntos de ignición y evaluar con perímetros implicaba comparar magnitudes diferentes.

Con el nuevo diseño se entrenó con los años 2015–2022, se ajustó con 2023 y se probó con 2024, evaluando siempre dentro de cada día.

Se compararon dos alternativas:

- Un modelo único.
- La combinación de un modelo de “dónde” (estático) con otro de “cuándo” (diario).

También se probaron diferentes cantidades de negativos por positivo. Finalmente se seleccionó el modelo único con diez negativos por positivo, denominado *r10*.

La elección se apoyó en la temporada de 2026, externa al datacubo y formada por 74 días con fuego. El modelo único obtuvo un AUC medio de 0.752, frente a 0.705 de la combinación de dos modelos.

Aunque en la prueba de 2024 la combinación había obtenido un resultado superior (0.840 frente a 0.809), esta ventaja no se mantuvo en 2026.

Las distintas cantidades de negativos por positivo produjeron diferencias reducidas en el AUC medio, entre 0.745 y 0.759. Sin embargo, utilizar diez negativos permitió situar mejor los incendios de mayor tamaño: el percentil medio de las celdas quemadas, ponderado por hectáreas, aumentó de 79.5 con tres negativos a 81.9 con diez.

Antes de dar por válido el modelo se analizó también la importancia de las variables mediante valores SHAP (*SHapley Additive exPlanations*).

La Figura 4 muestra las variables con mayor peso.




Figura 4: Variables de mayor importancia en el modelo *r10* según valores SHAP calculados sobre 6 000 celdas-día de los veranos de 2023 y 2024.

La variable de mayor peso fue el historial de incendios a 10 km durante el mismo mes de años anteriores. A continuación aparecieron variables relacionadas con el combustible, como el verdor acumulado, el matorral y la pendiente, seguidas de variables meteorológicas.

Una humedad mínima baja y un FWI anómalo para la propia celda aumentan el riesgo, mientras que el suelo agrícola y la lluvia reciente lo reducen. El verdor y la temperatura de superficie del propio día contienen parte de la firma del incendio en el datacubo y representan aproximadamente un 4 % del peso del modelo. En producción, estas variables se sustituyen por su climatología mensual al no estar disponibles en tiempo real.

3.5. Resultados, límites y conclusiones

Para comparar ambos modelos en igualdad de condiciones se reprodujeron día a día las temporadas de 2025, desde el 1 de junio hasta el 1 de noviembre, y de 2026, hasta el 2 de septiembre.

Ambos modelos recibieron la previsión meteorológica disponible la víspera y se evaluaron utilizando los perímetros de EFFIS.

Tabla 2: Acierto medio por día (AUC dentro del día) del modelo de producción y del modelo r10 con la previsión de la víspera, evaluados con EFFIS. La diferencia corresponde a la media pareada día a día, con intervalo de confianza bootstrap al 95 %.

Temporada	Días fuego	Hectáreas	Producción	r10	Diferencia (IC 95 %)	Días gana r10
2025	138	387 000	0.743	0.807	+0,064 [+0,027, +0,101]	60 %
2026	86	268 000	0.658	0.762	+0,104 [+0,065, +0,144]	67 %

De la comparación se extraen tres conclusiones principales.

En primer lugar, el modelo r10 supera al modelo inicial en ambas temporadas y obtiene una ventaja especialmente clara en 2026.

En segundo lugar, utilizar la previsión meteorológica disponible la víspera no supone una pérdida apreciable frente al uso del tiempo realmente observado. El rendimiento del modelo depende más de conocer el estado del combustible y el grado de sequedad que de predecir con precisión cada variable meteorológica.

En tercer lugar, el mapa generado por el sistema debe interpretarse como una herramienta para priorizar zonas de vigilancia y no como una predicción determinista de dónde se producirá un incendio. La probabilidad de que una celda concreta arda en un día concreto es extremadamente baja, por lo que el objetivo del modelo es ordenar correctamente las zonas de mayor riesgo.

Para facilitar la interpretación operativa se proponen dos formas de representar la salida: un mapa basado en percentiles diarios, que indica las celdas prioritarias dentro de cada jornada, y un mapa con umbrales absolutos, que permite comparar el nivel de riesgo entre días diferentes.

La Figura 5 muestra ambos enfoques.




Figura 5: Comparación de la salida del modelo r10 en un día de pleno verano y en otro fuera de temporada, utilizando tanto percentiles diarios como umbrales absolutos de riesgo.

La propuesta presenta varias limitaciones. La evaluación de las temporadas de 2025 y 2026 es retrospectiva: aunque se utilizaron las previsiones disponibles la víspera, los mapas se generaron posteriormente y no fueron publicados de forma continua durante toda la temporada.

Además, la escala absoluta se calibró utilizando únicamente días de temporada, sin incluir los meses de diciembre a abril, y la cobertura se limita actualmente a la Península y Baleares.

Como conclusión, este módulo muestra que el diseño del problema de aprendizaje debe reproducir de forma fiel el uso operativo previsto. Un rendimiento elevado sobre un conjunto de prueba construido bajo la misma lógica que el entrenamiento no garantiza necesariamente que el modelo responda correctamente a la pregunta real.

La utilidad práctica del modelo r10 se observa en la temporada completa de 2025. Utilizando un radio operativo de 6 km, se cubrió aproximadamente el 44 % de los incendios vigilando cerca del 10 % del territorio. Este resultado permite plantear el modelo como una herramienta para concentrar recursos de vigilancia, por ejemplo mediante cámaras o drones, en aquellas zonas con mayor riesgo estimado.

Por último cabe mencionar que el sistema está en marcha. Cada madrugada, GitHub Actions ejecuta la cadena completa: descarga la previsión del IFS para hoy y para mañana, calcula las 46 variables en toda la malla de 1 km, puntúa cada celda con el r10 y publica los dos mapas de ambos días con la cifra correspondiente. Cuando llegan los perímetros de EFFIS y el parte de incidentes del MITECO, la cadena redibuja los mapas de los veinte días anteriores con esas fuentes de verdad, de modo que puede comprobarse sobre el propio mapa si los incendios y las áreas quemadas caen en las zonas que se habían señalado. En los trece primeros días de septiembre de 2026, con el nivel extremo entre el 0.2 y el 1.6 % de España, cayó en él el 22 % de las celdas quemadas del día y el 37 % de los incidentes del MITECO.

Todo el código está disponible en el repositorio y los mapas de los últimos veinte días, en su carpeta.

4. Visión artificial y detección temporal

La parte visual del sistema se planteó desde dos perspectivas complementarias. Por un lado, se buscó detectar y localizar directamente regiones de humo o fuego dentro de una imagen. Y por otro lado, se estudió cómo evoluciona esa evidencia visual a lo largo del tiempo en secuencias obtenidas por cámaras fijas.

Para ello se utilizaron dos conjuntos de datos con características diferentes. D-Fire se empleó para entrenar un detector de objetos capaz de identificar y localizar fuego y humo mediante *bounding boxes*. FIgLib/HPWREN, en cambio, permitió trabajar con secuencias temporales y analizar tanto la presencia global de humo en cada imagen como la persistencia de esa señal a lo largo del tiempo.

De esta forma, ambos enfoques cubren aspectos distintos del problema: D-Fire aporta información espacial sobre la localización del fuego o el humo, mientras que FIgLib permite estudiar si existe evidencia visual consistente y cómo esta cambia a medida que avanza el evento. En conjunto, el bloque visual combina localización espacial, clasificación global y modelización temporal.

4.1. Detección espacial mediante YOLO11

Sobre el conjunto D-Fire se entrenó un detector YOLO11s [3] preentrenado, utilizando imágenes de entrada de 960×960 píxeles, *batch size* 16 y un máximo de 100 épocas. La elección del modelo e hiperparámetros, así como la evaluación de distintos modelos y la discusión de errores, se encuentran detalladas en el Anexo C.

Los resultados principales sobre el conjunto de test se muestran en la Tabla 3.

Tabla 3: Resultados globales del detector YOLO11s sobre D-Fire.

Métrica	Test
Precision	0.7891
Recall	0.7208
mAP@0.50	0.7311
mAP@0.50:0.95	0.4358

La diferencia entre mAP@0.50 y mAP@0.50:0.95 indica que el modelo presenta una capacidad razonable para detectar los objetos, pero sufre una penalización cuando se exige una localización más precisa de las *bounding boxes*.

Este comportamiento es especialmente relevante en un sistema de alerta temprana, donde detectar la presencia del fenómeno puede resultar más importante que delimitar perfectamente sus bordes.

De hecho, cuando el problema se reformuló como presencia o ausencia de fuego o humo, independientemente de la precisión espacial de la *bounding box*, el rendimiento aumentó considerablemente:

Escenario	Precision	Recall	F1
Fire	0.9330	0.9749	0.9535
Smoke	0.9365	0.9774	0.9565
Fire OR Smoke	0.9651	0.9848	0.9748

Tabla 4: Evaluación de presencia/ausencia para YOLO11s 960×960.

Este resultado muestra que una parte relevante del error de las métricas estándar procede de problemas de localización o detecciones duplicadas, y no necesariamente de la incapacidad del modelo para reconocer visualmente fuego o humo.

4.2. Influencia del tamaño de los objetos

Uno de los resultados más relevantes del análisis de D-Fire fue la influencia del tamaño del objeto:

Clase y tamaño	Recall	IoU medio
Fire - Small	0.8519	0.6628
Fire - Medium	0.9445	0.6988
Fire - Large	0.9505	0.7181
Smoke - Small	0.8848	0.6752
Smoke - Medium	0.9059	0.7049
Smoke - Large	0.9695	0.7729

Tabla 5: Recall e IoU medio según clase y tamaño para 960×960 sobre test.

Por tanto, la capacidad de detección aumenta a medida que el objeto ocupa una mayor proporción de la imagen.

Esta observación resulta especialmente importante en detección temprana, ya que las primeras evidencias de un incendio pueden ocupar una región muy pequeña del campo de visión. Este resultado motivó también el análisis realizado sobre FigLib acerca del efecto de la resolución espacial.

4.3. Número de objetos por imagen

También se repitió el análisis según la densidad de objetos presentes en cada imagen. Para 960×960 se obtuvo:

Número de objetos	Recall (%)
1	84.78
2-3	80.36
4-5	72.59
6-10	75.22
> 10	59.41

Tabla 6: Recall según el número de objetos para YOLO11s 960×960.

Las escenas densamente pobladas continúan siendo difíciles incluso con la resolución superior. En imágenes con más de diez objetos el recall desciende hasta 59.41 %. Por tanto, aumentar la resolución ayuda especialmente con objetos pequeños, pero no elimina las dificultades asociadas a escenas con muchos objetos simultáneos.

4.4. Clasificación visual sobre FgLib

FgLib/HPWREN contiene secuencias de imágenes capturadas por cámaras fijas de vigilancia y fue desarrollado específicamente para el estudio de la detección temprana de humo de incendios forestales [4]. A diferencia de D-Fire, su principal interés para este trabajo es la componente temporal, ya que cada imagen pertenece a un evento y está asociada a un desplazamiento temporal respecto a una referencia común.



Figura 6: Evolución temporal de un mismo evento observado desde la estación Mt. San Miguel North de HPWREN. La secuencia muestra la transición desde una escena sin humo visible hasta una situación en la que la columna de humo aparece claramente desarrollada.

La primera etapa consistió en entrenar un clasificador visual que, para cada imagen I_t , estima la probabilidad de presencia de humo:

$$p_t = P(\text{humo} \mid I_t), \quad (3)$$

donde I_t representa la imagen capturada en el instante t .

La separación entre entrenamiento, validación y test se realizó a nivel de evento, evitando que imágenes temporalmente cercanas de un mismo incendio apareciesen en subconjuntos distintos.

El etiquetado se definió de forma conservadora porque el instante $t = 0$ no representa necesariamente el primer momento en el que el humo resulta visible en la imagen. Para reducir el ruido de etiqueta, se consideraron negativas las imágenes con $t \leq -1200$ s, y positivas aquellas con $t \geq +900$ s. El intervalo intermedio se excluyó del entrenamiento visual supervisado.

De esta forma, el clasificador se entrenó únicamente con ejemplos de mayor confianza, evitando asumir que todo frame anterior a $t = 0$ no contiene humo o que todo frame inmediatamente posterior ya lo muestra de forma clara.

4.5. Efecto de la resolución

Se realizó una comparación controlada entre dos configuraciones basadas en ResNet18, con resoluciones de entrada de 224×224 y 384×384 píxeles. Ambos modelos utilizaron el mismo *split* de eventos y una metodología de entrenamiento equivalente, de forma que la resolución fuese la principal variable modificada entre ambas configuraciones.

Los resultados obtenidos se muestran en la Tabla 7.

Tabla 7: Comparación entre los clasificadores Full224 y Full384.

Métrica	Full224	Full384
Balanced Accuracy	0.7450	0.7989
Precision	0.8220	0.9019
Recall	0.6689	0.6906
AUC	0.7988	0.8386
FPR	0.1788	0.0927

El aumento de resolución produjo una mejora especialmente relevante en la tasa de falsos positivos, que se redujo de 0.1788 a 0.0927. En términos absolutos, el número de falsos positivos pasó de 301 a 156, lo que supone una reducción aproximada del 48 %. Al mismo tiempo, también aumentaron la *Balanced Accuracy*, la precisión, el recall y el AUC.

Para comprobar que estas diferencias no dependían únicamente de unos pocos eventos concretos, se realizó un bootstrap pareado a nivel de evento. El análisis confirmó que las mejoras observadas en *Balanced Accuracy* y FPR eran consistentes dentro del conjunto evaluado.

Este resultado está además en línea con lo observado en D-Fire: cuando el humo ocupa una región pequeña de la imagen, preservar una mayor cantidad de información espacial puede facilitar su detección. La comparación no permite concluir que aumentar indefinidamente la resolución vaya a mejorar siempre el rendimiento, pero sí muestra que, en este caso, 384×384 ofrece un comportamiento más favorable que 224×224 .

4.6. Información local y estrategias multiescala

También se analizó si incorporar información local de la imagen podía mejorar la sensibilidad del clasificador. Para ello se evaluó una estrategia multiescala que combinaba la representación global de la imagen con varias regiones locales.

Frente a Full384, el modelo multiescala aumentó el recall de 0.6906 a 0.7594. Sin embargo, esta mejora vino acompañada de un incremento considerable en la tasa de falsos positivos, que pasó de 0.0927 a 0.1771.

Los resultados sugieren que las regiones locales aportan información útil para detectar señales de humo difíciles de identificar a escala global, pero también aumentan la sensibilidad frente a patrones ambiguos, como nubes, bruma o zonas con iluminación intensa.

Debido a este compromiso entre sensibilidad y falsas detecciones, se mantuvo Full384 como modelo visual de referencia, al ofrecer un comportamiento más equilibrado en el conjunto evaluado.

4.7. De la clasificación visual a la detección temporal

Una cámara de vigilancia genera una secuencia de imágenes:

$$I_1, I_2, \dots, I_T. \quad (4)$$

Decidir una alerta a partir de cada frame de forma independiente puede resultar demasiado sensible a activaciones aisladas. Para introducir persistencia temporal, se estudiaron distintas reglas causales sobre las probabilidades generadas por Full384, entre ellas detecciones consecutivas y medias móviles.

La estrategia seleccionada sobre el conjunto de validación fue una media móvil de cinco observaciones:

$$\bar{p}_t = \frac{1}{5} \sum_{j=0}^4 p_{t-j}. \quad (5)$$

donde p_t representa la probabilidad estimada de presencia de humo en el instante t . La alerta se genera cuando esta probabilidad suavizada supera el umbral definido durante la validación.

Con esta estrategia se detectó el 88 % de los eventos posteriores a la referencia temporal, con una mediana de retraso de 361 segundos. Al mismo tiempo, el 18 % de los eventos presentó alguna alerta en la región claramente pre-evento.

4.8. Modelado temporal mediante GRU

Con el objetivo de sustituir las reglas temporales definidas manualmente por un mecanismo aprendido a partir de los datos, se entrenó un modelo recurrente de tipo GRU (*Gated Recurrent Unit*) [5].

Para cada instante t , se construyó un vector de características a partir de la salida del clasificador visual:

$$x_t = (p_t, \Delta p_t, \Delta t_t), \quad (6)$$

donde p_t es la probabilidad de presencia de humo estimada por Full384, $\Delta p_t = p_t - p_{t-1}$, representa la variación de dicha probabilidad respecto a la observación anterior, y Δt_t recoge el intervalo temporal entre ambas observaciones.

La GRU procesa ventanas causales de ocho observaciones, $x_{t-7}, \dots, x_t$, por lo que en cada instante utiliza únicamente información disponible hasta ese momento, sin acceder a observaciones futuras. A partir de esta secuencia, el modelo genera una probabilidad de alerta.

La Figura 7 resume este proceso.




Figura 7: Pipeline visual-temporal basado en FgLib. Full384 estima la probabilidad de presencia de humo para cada imagen. A partir de estas predicciones se construyen características temporales que se agrupan en ventanas causales de ocho observaciones y son procesadas por la GRU para generar una probabilidad de alerta.

4.9. Resultados temporales

La comparación entre la estrategia heurística basada en media móvil y el modelo GRU se muestra en la Tabla 8.

Tabla 8: Comparación entre la regla temporal heurística y la GRU.

Métrica	Rolling mean 5	GRU
Detección post- $t = 0$	0.88	0.96
Antes de 300 s	0.36	0.56
Antes de 600 s	0.58	0.72
Antes de 900 s	0.72	0.90
Antes de 1800 s	0.88	0.94
Clear-pre alert	0.18	0.28
Mediana retraso	361 s	210.5 s
Eventos no detectados	6	2

La GRU mostró una detección más rápida y una mayor cobertura de eventos. Antes de 900 segundos desde la referencia temporal, la proporción de eventos detectados aumentó del 72 % al 90 %, mientras que la mediana del tiempo hasta la primera alerta se redujo de 361 a 210.5 segundos, aproximadamente un 42 %.

Esta mejora en rapidez y sensibilidad tiene un coste. La proporción de eventos con alguna activación en la región claramente pre-evento aumentó del 18 % al 28 %. Por tanto, los dos enfoques representan compromisos distintos: la media móvil es más conservadora frente a falsas activaciones, mientras que la GRU prioriza una detección más temprana y una mayor sensibilidad.

4.10. Síntesis del bloque visual

Los experimentos realizados con D-Fire y FIgLib muestran que la detección temprana está fuertemente condicionada por la cantidad de información visual disponible. Para ambos datasets, los objetos de menor tamaño presentan un recall inferior y el aumento de la resolución de entrada permite reducir de forma notable la tasa de falsos positivos y mejorar el rendimiento global del clasificador. Ambos resultados apuntan a la dificultad de reconocer señales de humo cuando ocupan una región pequeña de la imagen.

También se observa una diferencia importante entre detectar la presencia del fenómeno y localizarlo con precisión. El detector YOLO11s alcanza un F1 elevado cuando el problema se plantea como presencia o ausencia de fuego o humo, mientras que las métricas que exigen una localización espacial más precisa son inferiores.

Por último, el análisis temporal permite aprovechar información que no está disponible en una imagen aislada. La GRU consigue detectar una mayor proporción de eventos y reducir el tiempo hasta la primera alerta respecto a la regla basada en media móvil, aunque este aumento de sensibilidad también se traduce en un mayor número de activaciones en la región pre-evento.

En conjunto, el bloque visual combina tres niveles de información complementarios: la localización espacial proporcionada por D-Fire, la evidencia visual global obtenida con FIgLib y la persistencia temporal modelada mediante la GRU.

5. Contextualización documental mediante RAG

Ante la detección de un posible incendio, resulta necesario disponer de información fiable que permita conocer su situación y complementar las evidencias obtenidas por los modelos predictivos. Sin embargo, esta información puede encontrarse distribuida entre documentos publicados en fechas diferentes y resultar difícil de localizar y consultar de forma conjunta.

El objetivo de este módulo es desarrollar un sistema de generación aumentada por recuperación, *Retrieval-Augmented Generation* (RAG), capaz de obtener información documental sobre incendios mediante consultas en lenguaje natural. La solución transforma los documentos oficiales en registros estructurados,

selecciona el método de recuperación adecuado para cada pregunta y genera respuestas fundamentadas en las fuentes disponibles.

Dentro de la arquitectura multimodal de este trabajo, este componente aporta contexto documental a los módulos meteorológicos, visuales y temporales. No se utiliza para determinar si un incendio existe ni para validar automáticamente una detección, sino para recuperar la información oficial disponible sobre un posible evento. Por tanto, la ausencia de resultados debe interpretarse únicamente como la inexistencia de coincidencias en el corpus indexado y no como evidencia de que el incendio no exista.

El código fuente completo desarrollado para este módulo, junto con las instrucciones necesarias para su instalación y ejecución, se encuentra disponible en el repositorio indicado en el Anexo B.

5.1. Construcción y almacenamiento del corpus documental

5.1.1. Fuente y actualización del corpus

El corpus se construye a partir de los partes diarios publicados por el Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO). Estos documentos recogen las actuaciones de los medios estatales ante incendios forestales e informan sobre su ubicación, estado, recursos asignados y fecha de actualización.

No constituyen un inventario completo de incendios, por lo que las respuestas del sistema quedan limitadas a los partes disponibles e indexados. Con el fin de mostrar la estructura original de la fuente documental, el Anexo E incluye un ejemplo completo de uno de los partes de MITECO utilizados para construir el corpus.

La incorporación de nuevos documentos se automatiza mediante GitHub Actions. El proceso localiza el parte definitivo del día anterior, comprueba que sea un PDF válido y que su fecha sea coherente, y calcula una huella SHA-256 para detectar duplicados o revisiones. Un manifiesto conserva la procedencia de cada descarga.

Esta automatización actualiza el corpus bruto, mientras que el procesamiento y la indexación se ejecutan de forma independiente.

5.1.2. Extracción, snapshots y chunking

Los PDF mantienen una estructura visual relativamente estable, pero no contienen registros tabulares directamente utilizables. PyMuPDF extrae el texto línea por línea y conserva la página de origen. A continuación, las líneas se limpian y normalizan sin eliminar el contenido original, que se mantiene para garantizar la trazabilidad de la información.

La separación de los incendios requiere conservar el contexto geográfico, ya que los encabezados de comunidad autónoma y provincia no siempre se repiten en cada registro. El parser utiliza una máquina de estados que mantiene esta información hasta que aparece un nuevo encabezado.

Cada campo de localización abre un bloque y cierra el anterior, mientras que el resumen estadístico del parte marca el final de la sección. Los documentos que indican expresamente que no hubo actuaciones se aceptan con cero registros, mientras que un parte sin bloques identificables ni una declaración equivalente se considera un error de procesamiento.

La unidad documental resultante se denomina *snapshot* y representa el estado de un incendio en la fecha correspondiente a un parte. De cada bloque se extraen los datos necesarios para la recuperación, que posteriormente se validan mediante Pydantic. Si un mismo incendio aparece durante varios días, se genera un snapshot distinto para cada fecha, lo que permite conservar su evolución documental sin sobrescribir la información histórica.

El *chunking* no divide el texto en ventanas de longitud fija. Cada bloque correspondiente a un incendio

se considera una unidad semántica completa y se transforma en un chunk autosuficiente que incluye la información principal y su procedencia. Esta decisión evita separar artificialmente datos relacionados y permite que cada resultado recuperado pueda interpretarse de manera independiente.

Los snapshots se exportan en formato JSONL, con un objeto por línea, junto con un informe de validación. Este archivo actúa como fuente común para construir los diferentes sistemas de almacenamiento utilizados durante la recuperación.

5.1.3. Embeddings y almacenamiento

Los chunks se convierten en embeddings normalizados de 1024 dimensiones mediante el modelo multilingüe BAAI bge-m3 [6], distribuido a través de Hugging Face y ejecutado con Sentence Transformers.

ChromaDB almacena estos vectores junto con el texto, el identificador del snapshot y los metadatos necesarios para aplicar filtros antes de calcular la similitud semántica.

La indexación se realiza de forma incremental. Una firma combina el contenido del snapshot, el modelo empleado y la versión del índice, de modo que únicamente se recalculan los registros nuevos o modificados. Si no se detectan cambios, el proceso termina sin cargar el modelo de embeddings, evitando operaciones innecesarias.

A partir del mismo archivo JSONL se construye una base de datos SQLite con una representación reducida de los metadatos. Esta base se enlaza con ChromaDB mediante el identificador del snapshot y se utiliza para resolver operaciones exactas, como recuentos y búsquedas de fechas extremas, para las que la similitud vectorial no resulta adecuada.

De este modo, ambos almacenamientos cumplen funciones complementarias: ChromaDB permite recuperar documentos mediante similitud semántica y filtros de metadatos, mientras que SQLite proporciona resultados deterministas para consultas estructuradas.

5.2. Orquestación y ejecución del flujo de consulta

Las preguntas pueden contener referencias a turnos anteriores, condiciones geográficas o temporales, peticiones de recuento o cuestiones ajenas al dominio. Por ello, el sistema no se limita a vectorizar la consulta y recuperar los documentos más similares, sino que organiza su procesamiento en varias etapas.

La orquestación se implementa mediante LangGraph, que representa la consulta como un grafo de estados y define explícitamente sus bifurcaciones. Los modelos de lenguaje se reservan para las tareas que requieren interpretación lingüística o generación de texto, mientras que la validación, el enrutamiento y las consultas a las bases de datos permanecen controlados mediante código determinista.

La Figura 8 representa los nodos que componen el grafo y las rutas seguidas en función de la consulta y del tipo de recuperación requerido.




Figura 8: Flujo de nodos y rutas condicionales del sistema de consulta orquestado mediante LangGraph.

5.2.1. Ejecución y estado compartido

La aplicación carga una sola vez el modelo de embeddings, la colección de ChromaDB, el catálogo de metadatos y la conexión con SQLite. A continuación, crea el grafo y entra en un bucle conversacional que recibe preguntas por terminal.

Cada sesión obtiene un identificador UUID utilizado como *thread_id*, y todas las preguntas realizadas durante la ejecución comparten ese identificador. De esta forma, se reutilizan los recursos y se mantiene el historial sin repetir la inicialización en cada turno.

Los nodos intercambian información mediante *GraphState*. Este estado conserva los mensajes, la consulta interpretada, los filtros, el modo de recuperación, el contexto y la respuesta. El historial se acumula durante la conversación, mientras que los resultados técnicos se reinician al comenzar cada turno para evitar que una recuperación anterior interfiera en la siguiente.

5.2.2. Preparación e interpretación de la consulta

El nodo *PrepareTurn* identifica la última pregunta del usuario y limpia el estado técnico del turno anterior. A continuación, *RewriteQuery* comprueba si la consulta depende del historial. En el primer turno devuelve directamente la pregunta, mientras que en los posteriores puede utilizar Gemma 4 31B [7] para convertir referencias como “¿Y los controlados?” en una consulta autosuficiente. Para limitar el contexto enviado al modelo se utilizan únicamente los ocho mensajes más recientes.

Bouncer clasifica después la intención como GO o NO GO. Las preguntas ajenas a los partes de incendios terminan con una respuesta automática, sin consultar el corpus.

Las aceptadas pasan a *DeterministicAnalysis*, que identifica filtros geográficos, estados y fechas mediante reglas lingüísticas, incluidas exclusiones, intervalos y expresiones referidas al presente.

El análisis determinista mantiene separadas la consulta semántica y las condiciones estructuradas, pero puede fallar ante relaciones lingüísticas complejas. Por ejemplo, en “incendios en Andalucía y León” podría combinar una comunidad y una provincia mediante AND, aunque la intención sea consultar ambos territorios mediante OR.

Reviewer utiliza un modelo de lenguaje para comprobar la coherencia y la suficiencia de los filtros. Su

salida validada puede conservarlos, ampliarlos, sustituirlos o solicitar una aclaración.

En los casos de ampliación o sustitución, *GenerateFilter* propone condiciones estructuradas y *ResolveWhere* las valida antes de generar el filtro final. El modelo no produce una consulta libre que pueda ejecutarse directamente sobre ChromaDB.

5.2.3. Selección y ejecución de la recuperación

RetrievalMode determina la operación adecuada para la pregunta. El sistema implementa tres modos principales de recuperación:

- Búsqueda híbrida
- Obtención de fechas extremas
- Recuento

La búsqueda híbrida aplica primero los filtros de metadatos y ordena después los snapshots compatibles según su similitud semántica, recuperando como máximo diez resultados. De esta forma, se evita que un documento próximo por su contenido, pero perteneciente a otra fecha o territorio, desplace a los registros que realmente cumplen las condiciones de la consulta.

Las preguntas sobre la primera o la última fecha se resuelven mediante la ruta de mínimo o máximo. SQLite calcula el extremo dentro del conjunto filtrado y ChromaDB recupera los documentos asociados a esa fecha.

Las peticiones de recuento también se calculan mediante SQLite, distinguiendo entre incendios, snapshots e informes, sin generar embeddings ni recuperar documentos completos.

Todos los modos devuelven un contrato común que contiene los documentos, los metadatos y, cuando corresponde, el resultado agregado. El selector también reconoce preguntas sobre cronologías, aunque esta ruta todavía no se encuentra conectada al grafo y se mantiene como posible ampliación.

5.2.4. Construcción de la respuesta y persistencia

GenerateContext transforma los resultados de la recuperación en un contexto común. Los valores exactos se incorporan como datos estructurados y los documentos recuperados como fragmentos numerados.

Finalmente, *GenerateAnswer* utiliza Gemma 4 31B mediante Ollama Cloud para redactar una respuesta limitada a la información disponible, indicando la fecha y la procedencia documental cuando los datos lo permiten.

El generador diferencia una recuperación vacía de un resultado exacto igual a cero. Cuando no existen coincidencias, limita expresamente la ausencia a los documentos indexados y no la presenta como información en tiempo real ni como prueba de que no exista un incendio.

La respuesta se añade al historial para que pueda utilizarse en los turnos posteriores.

El grafo se compila utilizando *SqliteSaver* como sistema de checkpoints. Los mensajes y los estados intermedios quedan asociados al *thread_id* de la conversación.

Esta información se mantiene separada tanto del índice vectorial como de la base utilizada para las consultas exactas, de manera que cada almacenamiento conserva una responsabilidad diferente.

Los checkpoints permanecen guardados después de cerrar el programa. Sin embargo, la interfaz actual genera un nuevo identificador en cada ejecución y todavía no permite seleccionar y reanudar directamente una conversación anterior desde la terminal.

5.3. Validación y limitaciones

En la versión evaluada para esta memoria se procesaron 58 partes y se generaron 324 snapshots. ChromaDB y SQLite contienen el mismo número de registros, y la suite automatizada incluye 141 pruebas sobre la descarga, el parser, la indexación, los filtros, los modos de recuperación, la generación de respuestas y las rutas principales del grafo.

El prototipo mantiene algunas limitaciones. La identificación de un mismo incendio entre partes se basa en una clave heurística, la recuperación completa de cronologías todavía no está implementada y la interfaz no permite recuperar una conversación anterior.

Además, el sistema depende de la cobertura y periodicidad de los documentos de MITECO, que recogen únicamente las intervenciones comunicadas por el organismo.

6. Conclusiones

6.1. Conclusiones generales

El trabajo ha permitido desarrollar una arquitectura modular para la detección y contextualización de incendios forestales a partir de información meteorológica, visual, temporal y documental.

En el módulo meteorológico se comprobó la importancia de formular el problema de aprendizaje de acuerdo con su uso real. Durante la temporada de 2025, el modelo permitió cubrir el 44 % de los incendios mediante la vigilancia de aproximadamente el 10 % del territorio, por lo que su utilidad reside en priorizar las zonas de observación y no en predecir de forma determinista dónde se producirá un incendio.

La parte visual confirmó que la detección resulta más difícil cuando el humo o el fuego ocupan regiones pequeñas de la imagen, y que aumentar la resolución puede mejorar el rendimiento y reducir los falsos positivos. En el detector basado en D-Fire, el análisis mostró que el principal parámetro de control del comportamiento del modelo es el umbral de confianza: aumentarlo reduce las falsas detecciones, pero también provoca una pérdida importante de recall.

Esto pone de manifiesto que, en un sistema de alerta temprana, no resulta adecuado optimizar únicamente la precisión, sino buscar un equilibrio entre sensibilidad y falsas alarmas. En la misma línea, el modelado temporal mediante GRU permitió detectar una mayor proporción de eventos y reducir el tiempo hasta la primera alerta, aunque a costa de un aumento de las activaciones prematuras.

Por su parte, el módulo RAG permitió estructurar y consultar en lenguaje natural los partes oficiales de MITECO, manteniendo la trazabilidad documental y combinando recuperación semántica con consultas exactas. Frente a un RAG convencional de flujo lineal, la orquestación mediante LangGraph permite interpretar cada pregunta y seleccionar el método de recuperación más adecuado.

En conjunto, los resultados muestran que los distintos módulos aportan información complementaria y pueden integrarse dentro de un sistema común de apoyo a la detección, priorización y contextualización de incendios forestales.

El despliegue operativo de un sistema integrado basado en estos tres pilares, apoyado en estaciones meteorológicas, cámaras, drones y otras fuentes de observación, podría mejorar la capacidad de vigilancia y respuesta frente a incendios forestales. La combinación de predicción de riesgo, detección temprana y contextualización de la información permitiría actuar con mayor rapidez y precisión, contribuyendo así a reducir su impacto social, económico y ambiental.

6.2. Limitaciones

La principal limitación del trabajo es que los distintos módulos se han entrenado y evaluado sobre conjuntos de datos diferentes, lo que impide medir el rendimiento del sistema completo mediante una única métrica

común. La disponibilidad de un conjunto de datos visuales geolocalizados y suficientemente amplio habría permitido, además, evaluar la integración del sistema sobre incendios reales ocurridos en España.

En la parte visual, el procesamiento de imágenes a alta resolución y el análisis temporal requieren una capacidad de cómputo considerable. El entrenamiento y la inferencia de este tipo de modelos dependen en gran medida de la disponibilidad de GPU, memoria y capacidad de procesamiento, lo que puede limitar su escalabilidad o su ejecución en tiempo real si se pretende desplegar el sistema sobre un gran número de cámaras o dispositivos.

A esto se suma el compromiso entre sensibilidad y falsas activaciones, especialmente en el modelo temporal, donde una mayor capacidad de detección temprana puede traducirse en un incremento de alertas prematuras.

Por último, el sistema RAG depende de la cobertura y periodicidad de los partes de MITECO, que no constituyen un inventario completo de incendios. Por este motivo, la ausencia de información en el corpus no puede interpretarse como evidencia de que no exista un incendio real.

Referencias

- [1] GAIA Solutions on Demand, *D-Fire Dataset*, GitHub repository, Accessed: 2026, 2024. dirección: <https://github.com/gaia-solutions-on-demand/DFireDataset>
- [2] M. Rodrigues y J. de la Riva, «An Insight into Machine-Learning Algorithms to Model Human-Caused Wildfire Occurrence,» *Environmental Modelling & Software*, vol. 57, págs. 192-201, 2014. DOI: 10.1016/j.envsoft.2014.03.003
- [3] Ultralytics, *YOLO11 Documentation*, Ultralytics Documentation, Accessed: 2026, 2024. dirección: <https://docs.ultralytics.com/models/yolo11/>
- [4] A. Dewangan et al., «F1gLib & SmokeyNet: Dataset and Deep Learning Model for Real-Time Wildland Fire Smoke Detection,» *Remote Sensing*, vol. 14, n.º 4, pág. 1007, 2022. DOI: 10.3390/rs14041007
- [5] K. Cho et al., «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation,» en *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*, Association for Computational Linguistics, 2014, págs. 1724-1734. DOI: 10.3115/v1/D14-1179
- [6] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian y Z. Liu, «BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,» en *Findings of the Association for Computational Linguistics: ACL 2024*, Bangkok, Thailand: Association for Computational Linguistics, 2024, págs. 2318-2335. DOI: 10.18653/v1/2024.findings-acl.137 dirección: <https://aclanthology.org/2024.findings-acl.137/>
- [7] Gemma Team, *Gemma 4 Technical Report*, 2026. DOI: 10.48550/arXiv.2607.02770 arXiv: 2607.02770 [cs.CL]. dirección: <https://arxiv.org/abs/2607.02770>